

MỤC LỤC

0.1	Đường ống dữ liệu	2
0.1.1	Đường ống dữ liệu Văn bản pháp luật	5
0.1.2	Đường ống dữ liệu Pháp Điển	13


0.1 Đường ống dữ liệu

Đường ống dữ liệu bao gồm các chuỗi quy trình xử lý tự động từ một hoặc nhiều nguồn (source) đến một đích đến (destination) để lưu trữ, phân tích hoặc phục vụ cho các ứng dụng khác. Vì dự án này làm về miền nghiệp vụ pháp luật nên không cần thu thập dữ liệu từ nhiều nguồn khác nhau. Em sử dụng dữ liệu chính thống từ nhà nước là **Văn bản pháp luật** tại địa chỉ <https://vbpl.vn> và dữ liệu **Pháp Điển** tại địa chỉ <https://phapdien.moj.gov.vn/Pages/chi-tiet-bo-phap-dien.aspx>. Pháp điển là tập hợp các quy phạm pháp luật đang còn hiệu lực của các văn bản quy phạm pháp luật do cơ quan nhà nước ở trung ương ban hành, từ Thông tư trở lên và trừ Hiến pháp. Giao diện nguồn dữ liệu Văn bản pháp luật



Hình 0.1: Giao diện nguồn dữ liệu Văn bản pháp luật

Giao diện nguồn dữ liệu Pháp Điển




Hình 0.2: Giao diện nguồn dữ liệu Pháp Điển

Sơ đồ thu thập dữ liệu chung:

- Sử dụng cron-job.org sẽ gửi một request đến GitHub API đúng theo khung giờ cấu hình. Cách này giúp bypass cơ chế schedule mặc định của GitHub Actions thường xuyên bị trễ từ 15 đến 30 phút.

- Lấy thông tin dữ liệu công việc từ database postgres và có kết quả phục vụ báo cáo cho giao diện quản trị viên ADMIN.
- Sử dụng framework python Scrapy để thu thập dữ liệu.
- Tải lên file dữ liệu kết quả đã được xử lý lên Google Drive để lưu trữ lâu dài.



Hình 0.3: Sơ đồ thu thập dữ liệu chung

Tại các bước sẽ sử dụng logic so sánh mã băm (hash) để bỏ qua văn bản không thay đổi nội dung giúp tiết kiệm tài nguyên và thời gian xử lý dữ liệu.

```


> step_crawl_document_detail 23s
> step_load_document_detail 34s
> step_extract_document_markdown 37s

1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_extract_document_markdown.py
13 2026-06-14 18:01:52.773 | INFO | env:<module>:7 - Loading environment variables...
14 2026-06-14 18:01:57.608 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:113 - Bắt đầu lấy và khóa task cho step_code='step_extract_document_markdown', limit=150
15 2026-06-14 18:01:58.041 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:148 - Đã khóa thành công 10 item(s) cho step_code='step_extract_document_markdown'.
16 2026-06-14 18:01:59.093 | INFO | __main__:document_markdown_resource:112 - Đang xử lý Markdown cho item: 154828
17 2026-06-14 18:01:59.093 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/1Ei49rF7C-quvxLAgCEh9SvFduj3F3Jd/view
18 2026-06-14 18:01:59.709 | INFO | __main__:document_markdown_resource:134 - Đã lưu file local: /home/runner/work/data-pipeline-vbp1new/data-pipeline-vbp1new/data/step_extract_document_markdown/154828.md
19 2026-06-14 18:01:59.897 | INFO | __main__:document_markdown_resource:151 - Bỏ qua 154828 vì nội dung Markdown không đổi trên Drive.
20 2026-06-14 18:01:59.898 | INFO | __main__:document_markdown_resource:112 - Đang xử lý Markdown cho item: 154833
21 2026-06-14 18:01:59.898 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/1q0h1g9Bh7azP8L517k7TH_6-1Ev5Nw/view
22 2026-06-14 18:02:00.404 | INFO | __main__:document_markdown_resource:134 - Đã lưu file local: /home/runner/work/data-pipeline-vbp1new/data-pipeline-vbp1new/data/step_extract_document_markdown/154833.md
23 2026-06-14 18:02:00.641 | INFO | __main__:document_markdown_resource:151 - Bỏ qua 154833 vì nội dung Markdown không đổi trên Drive.
24 2026-06-14 18:02:00.641 | INFO | __main__:document_markdown_resource:112 - Đang xử lý Markdown cho item: 166845
25 2026-06-14 18:02:00.641 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/1si0hQYBaeff90E-nE5uJ6S0R0d0ty1KE/view
26 2026-06-14 18:02:01.676 | INFO | __main__:document_markdown_resource:134 - Đã lưu file local: /home/runner/work/data-pipeline-vbp1new/data-pipeline-vbp1new/data/step_extract_document_markdown/166845.md
27 2026-06-14 18:02:01.858 | INFO | __main__:document_markdown_resource:151 - Bỏ qua 166845 vì nội dung Markdown không đổi trên Drive.
28 2026-06-14 18:02:01.858 | INFO | __main__:document_markdown_resource:112 - Đang xử lý Markdown cho item: 30462
29 2026-06-14 18:02:01.858 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/15mbzpxXhqe1mafH8P4hf3Hn2zeu17/view
30 2026-06-14 18:02:02.292 | INFO | __main__:document_markdown_resource:134 - Đã lưu file local: /home/runner/work/data-pipeline-vbp1new/data-pipeline-vbp1new/data/step_extract_document_markdown/30462.md
31 2026-06-14 18:02:03.168 | INFO | utils.google_drive:get_or_create_drive_folder:52 - Folder 'step_extract_document_markdown' đã tồn tại | ID: 1xf73doXB8Idbpya0ziBeubH7Nc8H8Iq
32 2026-06-14 18:02:03.170 | INFO | utils.google_drive:upload_to_drive:77 - Đang upload: 30462.md (MimeType: text/markdown)
33 2026-06-14 18:02:05.031 | SUCCESS | utils.google_drive:upload_to_drive:88 - File uploaded: 30462.md | ID: 15mbzpxXhqe1mafH8P4hf3Hn2zeu17
34 2026-06-14 18:02:05.031 | DEBUG | utils.google_drive:upload_to_drive:89 - Link: https://drive.google.com/file/d/15mbzpxXhqe1mafH8P4hf3Hn2zeu17/view
35 2026-06-14 18:02:05.031 | SUCCESS | main:document_markdown_resource:170 - Đã upload Markdown cho 30462 (Drive ID: 15mbzpxXhqe1mafH8P4hf3Hn2zeu17)

```

Hình 0.4: So sánh mã băm để bỏ qua văn bản

Thư viện dlt (Data Load Tool) là một thư viện Python mã nguồn mở giúp trích xuất dữ liệu từ nhiều nguồn khác nhau và tải chúng vào các tập dữ liệu có cấu trúc rõ ràng. Thay vì phải tự viết hàng trăm dòng code để định nghĩa bảng, ép kiểu dữ liệu và xử lý lỗi khi API thay đổi cấu trúc, Data Load Tool tự động hóa toàn bộ các công việc này một cách thông minh. Data Load Tool rất phù hợp với bài toán thu thập dữ liệu khi nguồn dữ liệu thay đổi cấu trúc.




Hình 0.5: Giao diện nguồn dữ liệu Văn bản pháp luật


Việc sử dụng Data Load Tool hỗ trợ tự động nội suy cấu trúc, kiểu dữ liệu và xử lý mượt mà các cấu trúc dữ liệu lồng nhau hỗ trợ tốt việc thay đổi nếu nguồn dữ liệu có sự thay đổi



Hình 0.6: Data Load Tool tự động thích ứng nguồn dữ liệu có sự thay đổi



Hình 0.7: swagger




Hình 0.8: swagger

0.1.1 Đường ống dữ liệu Văn bản pháp luật


Khi làm việc với bài toán dữ liệu thực tế, việc thu thập dữ liệu có thách thức phụ thuộc vào nguồn dữ liệu. Vào ngày 24/05/2026, nguồn dữ liệu Văn bản pháp luật được thay đổi cả hệ thống, API và giao diện. Do sự thay đổi lớn về dữ liệu thu thập nên hệ thống cần xử lý lại toàn bộ các bước trong luồng dữ liệu.

Giao diện nguồn dữ liệu Văn bản pháp luật mới:




Hình 0.9: Giao diện trang tìm kiếm của nguồn dữ liệu Văn bản pháp luật mới

Sơ đồ tổng quan luồng dữ liệu Văn bản pháp luật mới:



Hình 0.10: Sơ đồ tổng quan luồng dữ liệu Văn bản pháp luật mới

Các bước thực hiện cũ:



Hình 0.11: Sơ đồ các bước thực hiện của quy trình cũ

Mô tả các bước thực hiện cũ:

Quá trình luồng dữ liệu được chia thành 3 giai đoạn: Thu thập dữ liệu, Tiền xử lý văn bản và Tích hợp quy trình RAG.

Giai đoạn Khởi tạo:

- **step_setup_workflow** cập nhật danh sách và thứ tự các bước (workflow) vào CSDL PostgreSQL.

Giai đoạn Thu thập Dữ liệu:


- **step_crawl_document_total** và **step_load_document_total**: thu thập tổng số lượng văn bản pháp luật hiện có trên hệ thống web.

```

step_crawl_document_total
118 2026-06-16 01:39:27.288 | DEBUG | utils.request_helper:make_vbpl_page_request:33 - Đang tạo request cho trang 1: https://vbpl-bientap-gateway.moj.gov.vn/api/qtdc/public/doc/all
(quá proxy)
119 2026-06-16 01:39:27 [scrapy_user_agents.middlewares] DEBUG: Assigned User-Agent Mozilla/5.0 (Windows NT 6.3; WOW64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/47.0.2526.106
Safari/537.36
120 2026-06-16 01:39:28 [scrapy.core.downloader.tls] WARNING: Remote certificate is not valid for hostname "toeic.work.gd"; VerificationError(errors=
[DNISMismatch(mismatched_id=DNS_ID(hostname=b'toeic.work.gd'))])
121 2026-06-16 01:39:28 [scrapy.core.engine] DEBUG: Crawled (200) <POST https://toeic.work.gd/> (referer: None)
122 2026-06-16 01:39:28.861 | INFO | crawler.spiders.document_total_spider:parse:31 - Tổng số văn bản hiện tại trên API: 168986
123 2026-06-16 01:39:28 [scrapy.core.scrapen] DEBUG: Scraped from <200 https://toeic.work.gd/>
124 {'update_at': '2026-06-16T01:39:28.861172', 'total_count': 168986}
125 2026-06-16 01:39:28 [scrapy.core.engine] INFO: Closing spider (finished)
126
    
```

Hình 0.12: Thu thập tổng số lượng văn bản pháp luật

- **step_crawl_document_list** và **step_load_document_list**: Dựa vào sự chênh lệch tổng số lượng, tính toán số trang cần quét và thu thập danh sách các **item_id**.



- `step_crawl_document_detail` và `step_load_document_detail`: tải toàn bộ mã nguồn HTML trang chi tiết của từng văn bản và Upload các file HTML gốc này lên Google Drive, đồng thời lưu `drive_id` và mã băm MD5 hash vào database để quản lý thay đổi.



Giai đoạn Tiền xử lý Dữ liệu:

- **step_extract_document_info:** từ file HTML, bóc tách các siêu dữ liệu quan trọng (Meta-data) như: Số hiệu, Cơ quan ban hành, Ngày có hiệu lực, Người ký, v.v. và lưu vào database.
- **step_extract_document_content:** Làm sạch file HTML, cắt bỏ các phần thừa (header, footer, menu) và chỉ giữ lại phần nội dung (thẻ `div#toanvancontent`).
- **step_extract_document_markdown:** Chuyển đổi file HTML đã làm sạch sang định dạng Markdown.

```

step_extract_document_markdown 43s

1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_extract_document_markdown.py
13 2026-05-31 19:14:11.951 | INFO | env:<module>:7 - Loading environment variables...
14 2026-05-31 19:14:18.122 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:113 - Bắt đầu lấy và khóa task cho step_code='step_extract_document_markdown', limit=150
15 2026-05-31 19:14:18.678 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:148 - Đã khóa thành công 39 item(s) cho step_code='step_extract_document_markdown'.
16 2026-05-31 19:14:20.117 | INFO | __main__:document_markdown_resource:94 - [ ] Bỏ qua 128791: Văn bản có trạng thái 'Hết hiệu lực toàn bộ'.
17 2026-05-31 19:14:20.117 | INFO | __main__:document_markdown_resource:112 - Đang xử lý Markdown cho item: 128796
18 2026-05-31 19:14:20.118 | DEBUG | utils.google_drive:download_from_drive:105 - [ ] Đang tải file từ URL: https://drive.google.com/file/d/1PhyepGe1TaDtKf1vYX50a824zh4sJE/view
19 2026-05-31 19:14:20.613 | INFO | __main__:document_markdown_resource:134 - [ ] Đã lưu file local: /home/runner/work/data-pipeline-vbp1new/data-pipeline-vbp1new/data/step_extract_document_markdown/128796.md
20 2026-05-31 19:14:20.721 | INFO | __main__:document_markdown_resource:151 - [ ] Bỏ qua 128796 vì nội dung Markdown không đổi trên Drive.
21 2026-05-31 19:14:20.721 | INFO | __main__:document_markdown_resource:94 - [ ] Bỏ qua 128797: Văn bản có trạng thái 'Hết hiệu lực toàn bộ'.
22 2026-05-31 19:14:20.721 | INFO | __main__:document_markdown_resource:94 - [ ] Bỏ qua 128799: Văn bản có trạng thái 'Hết hiệu lực toàn bộ'.
23 2026-05-31 19:14:20.721 | INFO | __main__:document_markdown_resource:112 - Đang xử lý Markdown cho item: 128805
24 2026-05-31 19:14:20.721 | DEBUG | utils.google_drive:download_from_drive:105 - [ ] Đang tải file từ URL: https://drive.google.com/file/d/1Qmbyr20cY7Uk05LW8pNlsStHoKshY/view
25 2026-05-31 19:14:21.115 | INFO | __main__:document_markdown_resource:134 - [ ] Đã lưu file local: /home/runner/work/data-pipeline-vbp1new/data-pipeline-vbp1new/data/step_extract_document_markdown/128805.md
26 2026-05-31 19:14:21.245 | INFO | __main__:document_markdown_resource:151 - [ ] Bỏ qua 128805 vì nội dung Markdown không đổi trên Drive.
27 2026-05-31 19:14:21.246 | INFO | __main__:document_markdown_resource:112 - Đang xử lý Markdown cho item: 128806
28 2026-05-31 19:14:21.246 | DEBUG | utils.google_drive:download_from_drive:105 - [ ] Đang tải file từ URL: https://drive.google.com/file/d/1Tmg6GjnGHHU9osBUV6Taeg1Z0y6Atp/view
29 2026-05-31 19:14:21.533 | INFO | __main__:document_markdown_resource:134 - [ ] Đã lưu file local: /home/runner/work/data-pipeline-vbp1new/data-pipeline-vbp1new/data/step_extract_document_markdown/128806.md
30 2026-05-31 19:14:21.648 | INFO | __main__:document_markdown_resource:151 - [ ] Bỏ qua 128806 vì nội dung Markdown không đổi trên Drive.

```

Hình 0.16: Chuyển đổi nội dung HTML đã làm sạch sang Markdown

Giai đoạn Tích hợp RAG pipeline:

- **step_rag_summary:** Sử dụng LLM viết một bản tóm tắt ngắn gọn mô tả bức tranh toàn cảnh của văn bản pháp luật đó.

```

step_rag_summary 20m 58s

1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_rag_summary.py
13 2026-06-16 00:40:38.359 | INFO | env:<module>:7 - Loading environment variables...
14 2026-06-16 00:40:42.939 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:113 - Bắt đầu lấy và khóa task cho step_code='step_rag_summary', limit=40
15 2026-06-16 00:40:51.803 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:148 - Đã khóa thành công 40 item(s) cho step_code='step_rag_summary'.
16 2026-06-16 00:40:53.801 | INFO | __main__:document_summary_resource:113 - [ ] Đang tải và tóm tắt tài liệu: 152024
17 2026-06-16 00:40:53.801 | DEBUG | utils.google_drive:download_from_drive:105 - [ ] Đang tải file từ URL: https://drive.google.com/file/d/1x1zgwC3033HfHhguKpV36hrC3vLb9q/view
18 2026-06-16 00:40:54.990 | INFO | rag.llm:invoke_llm_chain:76 - [ ] Đang gọi Ollama...
19 2026-06-16 00:42:45.330 | INFO | utils.google_drive:get_or_create_drive_folder:52 - Folder 'step_rag_summary' đã tồn tại | ID: 1VddqPxbClny501dybhl2NFHT15Axs
20 2026-06-16 00:42:45.333 | INFO | utils.google_drive:upload_to_drive:77 - Đang upload: 152024.txt (MimeType: text/plain)
21 2026-06-16 00:42:47.233 | SUCCESS | utils.google_drive:upload_to_drive:88 - [ ] File uploaded: 152024.txt | ID: 1FUlbfTPuQoQwadyY3Y25a0GtG7uujtT
22 2026-06-16 00:42:47.233 | DEBUG | utils.google_drive:upload_to_drive:89 - Link: https://drive.google.com/file/d/1FUlbfTPuQoQwadyY3Y25a0GtG7uujtT/view
23 2026-06-16 00:42:47.233 | SUCCESS | __main__:document_summary_resource:141 - [ ] Đã cập nhật tóm tắt mới cho 152024
24 2026-06-16 00:42:47.386 | INFO | __main__:document_summary_resource:113 - [ ] Đang tải và tóm tắt tài liệu: 167147

```

Hình 0.17: Tự động tóm tắt văn bản bằng mô hình LLM

- **step_rag_chunking:** Chạy Semantic Chunking. LLM sẽ dựa vào bản tóm tắt và nội dung chi tiết để quyết định các "điểm cắt" tối ưu, chia nhỏ văn bản thành các đoạn (chunks) sao cho không bị đứt gãy ý nghĩa.

```

step_rag_chunking 8m 48s

1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_rag_chunking.py
13 2026-06-16 01:01:34.856 | INFO | env:<module>:7 - Loading environment variables...
14 2026-06-16 01:01:42.939 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:113 - Bắt đầu lấy và khóa task cho step_code='step_rag_chunking', limit=40
15 2026-06-16 01:01:43.435 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:148 - Đã khóa thành công 35 item(s) cho step_code='step_rag_chunking'.
16 2026-06-16 01:01:44.804 | INFO | __main__:document_chunking_resource:192 - [ ] Đang tải dữ liệu Markdown & Summary cho tài liệu: 152024
17 2026-06-16 01:01:44.804 | DEBUG | utils.google_drive:download_from_drive:105 - [ ] Đang tải file từ URL: https://drive.google.com/file/d/1x1zgwC3033HfHhguKpV36hrC3vLb9q/view
18 2026-06-16 01:01:45.821 | INFO | __main__:process_and_chunk:100 - [ ] Đang gọi LLM để định giá semantic chunking...
19 2026-06-16 01:01:46.087 | INFO | rag.llm:invoke_llm_chain:76 - [ ] Đang gọi Ollama...
20 2026-06-16 01:01:46.369 | INFO | __main__:process_and_chunk:107 - [ ] LLM Response: split_after: 3, 5, 8
21 2026-06-16 01:01:56.982 | INFO | __main__:document_chunking_resource:218 - [ ] Đã tạo 4 file chunks trong thư mục: /home/runner/work/data-pipeline-vbp1new/data-pipeline-vbp1new/data/step_rag_chunking/chunk_152024
22 2026-06-16 01:01:56.984 | INFO | __main__:document_chunking_resource:226 - [ ] Đang tải file nén lên Google Drive...
23 2026-06-16 01:01:57.660 | INFO | utils.google_drive:get_or_create_drive_folder:52 - Folder 'step_rag_chunking' đã tồn tại | ID: 1w5PiybW0e2fu6jleqfC1Vdw-c6Igt-B
24 2026-06-16 01:01:57.662 | INFO | utils.google_drive:upload_to_drive:77 - Đang upload: chunk_zip_152024.zip (MimeType: application/zip)
25 2026-06-16 01:01:59.426 | SUCCESS | utils.google_drive:upload_to_drive:88 - [ ] File uploaded: chunk_zip_152024.zip | ID: 1Jv267WnFfHbmx1PgH2DTRKfRw5BupsZT3
26 2026-06-16 01:01:59.427 | DEBUG | utils.google_drive:upload_to_drive:89 - Link: https://drive.google.com/file/d/1Jv267WnFfHbmx1PgH2DTRKfRw5BupsZT3/view
27 2026-06-16 01:01:59.427 | SUCCESS | __main__:document_chunking_resource:239 - [ ] Đã xử lý phân mảnh (chunking) thành công cho 152024 (Drive ID: 1Jv267WnFfHbmx1PgH2DTRKfRw5BupsZT3)
28 2026-06-16 01:01:59.567 | INFO | __main__:document_chunking_resource:192 - [ ] Đang tải dữ liệu Markdown & Summary cho tài liệu: 167147

```

Hình 0.18: Chia nhỏ văn bản dựa trên ý nghĩa (Semantic Chunking)

- **step_rag_context:** Đây là bước chống mất ngữ cảnh. LLM sẽ sinh ra ngữ cảnh cho từng đoạn chunk nhỏ vừa được cắt, đảm bảo mỗi chunk đều có thể đứng độc lập khi được tìm kiếm.

```

step_rag_context
13m 21s

1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_rag_context.py
13 2026-06-16 01:10:14.851 | INFO | env:<module>:7 - Loading environment variables...
14 2026-06-16 01:10:23.079 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:113 - Bắt đầu lấy và khóa task cho step_code='step_rag_context', limit=40
15 2026-06-16 01:10:23.573 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:148 - Đã khóa thành công 30 item(s) cho step_code='step_rag_context'.
16 2026-06-16 01:10:25.545 | INFO | __main__:document_context_resource:141 - Đang tải dữ liệu tóm tắt và chunks cho: 152024
17 2026-06-16 01:10:25.545 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/1FUIbftPuQoQwadyY3Y2Sa0GtG7uujWtT/view
18 2026-06-16 01:10:25.828 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/1Jv267MfPbnx1PgH2DTRKF-r6sBUqSZT3/view
19 2026-06-16 01:10:26.154 | INFO | __main__:document_context_resource:164 - Bắt đầu tạo ngữ cảnh cho 4 đoạn (chunks)...
20 2026-06-16 01:10:26.154 | INFO | __main__:document_context_resource:181 - Đang sinh ngữ cảnh cho chunk_2.md...
21 2026-06-16 01:10:26.462 | INFO | rag.llm:invoke_llm_chain:76 - Đang gọi Ollama...
22 2026-06-16 01:10:35.235 | INFO | __main__:document_context_resource:181 - Đang sinh ngữ cảnh cho chunk_1.md...
23 2026-06-16 01:10:35.910 | INFO | rag.llm:invoke_llm_chain:76 - Đang gọi Ollama...
24 2026-06-16 01:10:40.466 | INFO | __main__:document_context_resource:181 - Đang sinh ngữ cảnh cho chunk_3.md...
25 2026-06-16 01:10:40.771 | INFO | rag.llm:invoke_llm_chain:76 - Đang gọi Ollama...
26 2026-06-16 01:10:45.681 | INFO | __main__:document_context_resource:181 - Đang sinh ngữ cảnh cho chunk_4.md...
27 2026-06-16 01:10:46.489 | INFO | rag.llm:invoke_llm_chain:76 - Đang gọi Ollama...
28 2026-06-16 01:10:55.977 | INFO | __main__:document_context_resource:206 - Đang tải file Context Zip lên Google Drive...
29 2026-06-16 01:10:56.494 | INFO | utils.google_drive:get_or_create_drive_folder:52 - Folder 'step_rag_context' đã tồn tại | ID: 1v0fe41aPMe_zu_y5QhEWZiaUrN0C7Tt
30 2026-06-16 01:10:56.497 | INFO | utils.google_drive:upload_to_drive:77 - Đang upload: contextualized_152024.zip (MimeType: application/zip)
31 2026-06-16 01:10:58.250 | SUCCESS | utils.google_drive:upload_to_drive:88 - File uploaded: contextualized_152024.zip | ID: 18U8Mo00g74ybUoDpuX9qGYGF0Y2-tp1p
32 2026-06-16 01:10:58.250 | DEBUG | utils.google_drive:upload_to_drive:89 - Link: https://drive.google.com/file/d/18U8Mo00g74ybUoDpuX9qGYGF0Y2-tp1p/view
33 2026-06-16 01:10:58.250 | SUCCESS | __main__:document_context_resource:219 - Đã xử lý ngữ cảnh thành công cho 152024
34 2026-06-16 01:10:58.557 | INFO | __main__:document_context_resource:141 - Đang tải dữ liệu tóm tắt và chunks cho: 167147
35 2026-06-16 01:10:58.557 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/1xx3ja1j3g60DxC8mpvEKpLTH6HHe8i/view
36 2026-06-16 01:10:58.889 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/1BKFgktQskTYSw4Q3_BT6bqn10orBdLAQ/view
37 2026-06-16 01:10:59.191 | INFO | __main__:document_context_resource:164 - Bắt đầu tạo ngữ cảnh cho 1 đoạn (chunks)...
38 2026-06-16 01:10:59.191 | INFO | __main__:document_context_resource:181 - Đang sinh ngữ cảnh cho chunk_1.md...

```

Hình 0.19: Làm giàu ngữ cảnh cho từng đoạn văn bản nhỏ

- **step_rag_embedding:** Sử dụng mô hình HuggingFace (keepitreal/vietnamese-sbert) để biến đổi các đoạn văn bản (đã có ngữ cảnh) thành vector đa chiều và lưu trữ vào VectorDB (Pinecone).

```


step_rag_embedding
55s

1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_rag_embedding.py
13 2026-06-16 01:20:37.004 | INFO | env:<module>:7 - Loading environment variables...
14 Loading weights: 0% | 0/199 [00:00<, ?it/s]
15 Loading weights: 100% | 199/199 [00:00<00, 22892.04it/s]
16 2026-06-16 01:20:59.683 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:113 - Bắt đầu lấy và khóa task cho step_code='step_rag_embedding', limit=150
17 2026-06-16 01:21:00.345 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:148 - Đã khóa thành công 26 item(s) cho step_code='step_rag_embedding'.
18 2026-06-16 01:21:00.345 | INFO | __main__:document_embedding_resource:54 - Đang fetch toàn bộ metadata và history hàng loạt cho 26 items...
19 2026-06-16 01:21:07.816 | INFO | __main__:document_embedding_resource:176 - Đang tải và giải nén Chunks (Context) cho tài liệu: 152024
20 2026-06-16 01:21:07.817 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/18U8Mo00g74ybUoDpuX9qGYGF0Y2-tp1p/view
21 2026-06-16 01:21:08.099 | INFO | __main__:document_embedding_resource:191 - Đang tạo vector và lưu vào database cho 4 chunks...
22 2026-06-16 01:21:10.188 | SUCCESS | __main__:document_embedding_resource:256 - Đã lưu 4 vectors vào Vector DB cho: 152024
23 2026-06-16 01:21:10.344 | INFO | __main__:document_embedding_resource:176 - Đang tải và giải nén Chunks (Context) cho tài liệu: 167155
24 2026-06-16 01:21:10.344 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/1sB6dx0Bq1wzgjP71XYrfu7K3qk8dP8TP/view
25 2026-06-16 01:21:10.602 | INFO | __main__:document_embedding_resource:191 - Đang tạo vector và lưu vào database cho 1 chunks...

```


Hình 0.20: Nhúng văn bản (Embedding) và lưu vào CSDL Pinecone

Các bước thực hiện mới:



Hình 0.21: Sơ đồ các bước thực hiện của quy trình mới

- Nhờ vào việc nguồn dữ liệu thay đổi sang hệ thống API mới trả về cấu trúc JSON giàu thông tin, hệ thống không còn cần các bước bóc tách thủ công từ mã nguồn HTML phức tạp, giúp tăng tốc độ xử lý và độ chính xác của dữ liệu.
- Hệ thống loại bỏ bước `step_extract_document_info` vì nội dung Metadata chi tiết đã có trong API.
- Hệ thống loại bỏ bước `step_extract_document_content` vì nội dung văn bản đã được API trả trong thông tin `documentContent`.




Hình 0.22: Sơ đồ cấu hình GitHub Actions vận hành workflow mới


Kết quả vận hành thành công đường ống dữ liệu Văn bản pháp luật mới:

2026-06-16 01:01:15.216	SUCCESS	utils.workflow_helper:get_document_state_count_by_workflow:174 - Đã lấy thành công thống kê cho workflow
2026-06-16 01:01:15.222	DEBUG	utils.workflow_helper:get_document_state_count_by_workflow:201 - ID: 6, Count: 63
2026-06-16 01:01:15.222	DEBUG	utils.workflow_helper:get_document_state_count_by_workflow:201 - ID: 10, Count: 74798
2026-06-16 01:01:15.222	DEBUG	utils.workflow_helper:get_document_state_count_by_workflow:201 - ID: 14, Count: 92572
2026-06-16 01:01:18.594	SUCCESS	utils.workflow_helper:check_status_with_document_count:301 - Đã lấy thành công thống kê document theo status.
2026-06-16 01:01:18.594	INFO	utils.workflow_helper:check_status_with_document_count:305 - Còn hiệu lực(CHL): 72096
2026-06-16 01:01:18.594	INFO	utils.workflow_helper:check_status_with_document_count:305 - Không còn phù hợp(KCPH): 255
2026-06-16 01:01:18.594	INFO	utils.workflow_helper:check_status_with_document_count:305 - Chưa xác định(5): 0
2026-06-16 01:01:18.594	INFO	utils.workflow_helper:check_status_with_document_count:305 - Hết hiệu lực một phần(HHL1P): 5290
2026-06-16 01:01:18.594	INFO	utils.workflow_helper:check_status_with_document_count:305 - Ngưng hiệu lực một phần(TNHL1P): 2
2026-06-16 01:01:18.594	INFO	utils.workflow_helper:check_status_with_document_count:305 - Ngưng hiệu lực(TNHL): 369
2026-06-16 01:01:18.594	INFO	utils.workflow_helper:check_status_with_document_count:305 - Chưa có hiệu lực(CCHL): 149
2026-06-16 01:01:18.594	INFO	utils.workflow_helper:check_status_with_document_count:305 - Hết hiệu lực toàn bộ(HHL): 86641

Hình 0.23: Kết quả chạy thành công các bước của luồng dữ liệu mới (Phần 1)




Hình 0.24: Kết quả chạy thành công các bước của luồng dữ liệu mới (Phần 2)



Hình 0.25: Kết quả chạy thành công các bước của luồng dữ liệu mới (Phần 3)


0.1.2 Đường ống dữ liệu Pháp Diễn

Sơ đồ tổng quan Data pipeline Pháp Diễn




Hình 0.26: Sơ đồ thu thập dữ liệu chung

Tổng quan thông tin file zip




Hình 0.27: Sơ đồ thu thập dữ liệu chung

Kết quả file JSON đã trích xuất




Hình 0.28: Sơ đồ thu thập dữ liệu chung

Kết quả vector được lưu trong vector database



Hình 0.29: Sơ đồ thu thập dữ liệu chung

Các bước thực hiện



Hình 0.30: Sơ đồ thu thập dữ liệu chung

Mô tả các bước thực hiện:

Quá trình Data pipeline được chia thành 3 giai đoạn: Thu thập dữ liệu, Tiền xử lý văn bản và Tích hợp RAG Pipeline.

Giai đoạn Thu thập Dữ liệu:

- **step_download_zip:** Tự động tải file nén chứa toàn bộ Bộ pháp điển điện tử từ nguồn Cổng thông tin điện tử pháp điển. Hệ thống tính toán mã băm (MD5) và đồng bộ với Google Drive để kiểm tra sự thay đổi dữ liệu.

```

1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_download_zip.py
13
13 2026-06-16 00:46:34.230 | INFO | env:<module>:7 - Loading environment variables...
14 2026-06-16 00:46:34.786 | INFO | __main__:download_file:26 - ⚡ Đang tải file từ: https://phapdien.moj.gov.vn/TraCuuPhapDien/Files/BoPhapDienDienTu.zip
15 2026-06-16 00:47:21.262 | SUCCESS | __main__:download_file:34 - Tải xong: /home/runner/work/data-pipeline-phapdien/data-pipeline-phapdien/data/step_download_zip/phapdien_latest.zip
16 2026-06-16 00:47:23.052 | INFO | utils.google_drive:get_or_create_drive_folder:70 - ⚡ Đã tạo folder mới 'step_download_zip' | ID: 1rW61IVrHj0h0sqQB08ZlxFRi3b5hok
17 2026-06-16 00:47:23.536 | INFO | utils.google_drive:sync_local_file_to_drive:246 - ⚡ Phát hiện thay đổi (Tạo file mới). Đang đồng bộ 'phapdien_latest.zip' lên Drive...
18 2026-06-16 00:47:26.963 | DEBUG | utils.google_drive:upload_file_to_drive:186 - 📁 Đang tạo file mới 'phapdien_latest.zip'
19 2026-06-16 00:47:26.241 | SUCCESS | utils.google_drive:sync_local_file_to_drive:253 - ✅ Đồng bộ thành công: phapdien_latest.zip
20 2026-06-16 00:47:26.241 | DEBUG | __main__:main:66 - 🔗 Link: https://drive.google.com/file/d/1KL0HmG_t99jCtpIA5CmYr0tbyAZL2b/view
21 2026-06-16 00:47:26.241 | INFO | __main__:main:66 - ⚡ File ZIP có sự thay đổi. Đang tiến hành giải nén dữ liệu...
22 2026-06-16 00:47:26.720 | SUCCESS | __main__:extract_zip:43 - 📁 Đã giải nén vào: /home/runner/work/data-pipeline-phapdien/data-pipeline-phapdien/data/step_download_zip/extracted
23 2026-06-16 00:47:26.720 | INFO | __main__:main:76 - 📁 Đang tạo bản lưu trữ: phapdien_2026_06_16_00_47_26_720835.zip
24 2026-06-16 00:47:26.728 | DEBUG | utils.google_drive:upload_file_to_drive_with_metadata:213 - ⚡ Đang tải file 'phapdien_2026_06_16_00_47_26_720835.zip' lên Drive...

```

Hình 0.31: Tự động tải file nén mới và đồng bộ Google Drive

```

1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_download_zip.py
13
13 2026-06-16 00:08:57.470 | INFO | env:<module>:7 - Loading environment variables...
14 2026-06-16 00:08:57.930 | INFO | __main__:download_file:26 - ⚡ Đang tải file từ: https://phapdien.moj.gov.vn/TraCuuPhapDien/Files/BoPhapDienDienTu.zip
15 2026-06-16 00:08:15.819 | SUCCESS | __main__:download_file:34 - Tải xong: /home/runner/work/data-pipeline-phapdien/data-pipeline-phapdien/data/step_download_zip/phapdien_latest.zip
16 2026-06-16 00:08:16.615 | INFO | utils.google_drive:get_or_create_drive_folder:58 - Folder 'step_download_zip' đã tồn tại | ID: 1-sv4HPa4UEXihvdQpMGf80lafJ5uwl-
17 2026-06-16 00:08:17.160 | INFO | utils.google_drive:sync_local_file_to_drive:241 - 📁 File 'phapdien_latest.zip' không thay đổi (MD5 khớp). Bỏ qua upload.
18 2026-06-16 00:08:17.160 | SUCCESS | __main__:main:88 - ✅ File ZIP không đổi. Bỏ qua bước giải nén và các step tiếp theo trên GitHub Actions.

```

Hình 0.32: Kiểm tra mã băm và bỏ qua bước tải nếu không có sự thay đổi dữ liệu

Giai đoạn Tiền xử lý Dữ liệu:

- **step_extract_json** và **step_load_json**: Từ file `jsonData.js`, tiến hành bóc tách (parse) các biến cấu trúc dữ liệu để lấy danh sách Chủ đề (`jdChuDe`), Đề mục (`jdDeMuc`) và Cây mục lục (`jdAllTree`), sau đó xuất ra định dạng JSON.

```

1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_extract_json.py
13
13 2026-06-16 00:47:29.646 | INFO | env:<module>:7 - Loading environment variables...
14 2026-06-16 00:47:30.468 | INFO | utils.google_drive:get_or_create_drive_folder:58 - Folder 'step_extract_json' đã tồn tại | ID: 1lQl0zY22yhFkuyR8Pnm4f_SIOHkdnJ
15 2026-06-16 00:47:30.981 | INFO | utils.google_drive:sync_local_file_to_drive:241 - 📁 File 'jsonData.js' không thay đổi (MD5 khớp). Bỏ qua upload.
16 2026-06-16 00:47:30.981 | INFO | __main__:main:64 - ⚡ Bắt đầu trích xuất các biến dữ liệu từ file 35...
17 2026-06-16 00:47:34.156 | SUCCESS | __main__:main:81 - 📁 Trích xuất và lưu file local: jdChuDe.json
18 2026-06-16 00:47:34.158 | SUCCESS | __main__:main:81 - 📁 Trích xuất và lưu file local: jdDeMuc.json
19 2026-06-16 00:47:34.585 | SUCCESS | __main__:main:81 - 📁 Trích xuất và lưu file local: jdAllTree.json

```

Hình 0.33: Bóc tách biến cấu trúc dữ liệu và xuất ra file JSON

```

1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_load_json.py
13
13 2026-06-16 00:47:36.584 | INFO | env:<module>:7 - Loading environment variables...
14 2026-06-16 00:47:36.728 | INFO | __main__:main:25 - ⚡ Khởi tạo tiến trình load JSON...
15 2026-06-16 00:47:37.556 | INFO | utils.google_drive:get_or_create_drive_folder:58 - Folder 'step_load_json' đã tồn tại | ID: 1C5-hV_6Q_xcIfE_zH4EDDCb32xesqLh
16 2026-06-16 00:47:37.615 | INFO | __main__:main:45 - 🔍 Kiểm tra thay đổi file: jdChuDe.json
17 2026-06-16 00:47:38.147 | INFO | utils.google_drive:sync_local_file_to_drive:241 - 📁 File 'jdChuDe.json' không thay đổi (MD5 khớp). Bỏ qua upload.
18 2026-06-16 00:47:38.147 | INFO | __main__:main:52 - 📁 File 'jdChuDe.json' không thay đổi. Bỏ qua nạp Database.
19 2026-06-16 00:47:38.147 | INFO | __main__:main:45 - 🔍 Kiểm tra thay đổi file: jdDeMuc.json
20 2026-06-16 00:47:38.622 | INFO | utils.google_drive:sync_local_file_to_drive:241 - 📁 File 'jdDeMuc.json' không thay đổi (MD5 khớp). Bỏ qua upload.
21 2026-06-16 00:47:38.622 | INFO | __main__:main:52 - 📁 File 'jdDeMuc.json' không thay đổi. Bỏ qua nạp Database.
22 2026-06-16 00:47:38.622 | INFO | __main__:main:45 - 🔍 Kiểm tra thay đổi file: jdAllTree.json
23 2026-06-16 00:47:39.072 | INFO | utils.google_drive:sync_local_file_to_drive:241 - 📁 File 'jdAllTree.json' không thay đổi (MD5 khớp). Bỏ qua upload.
24 2026-06-16 00:47:39.072 | INFO | __main__:main:52 - 📁 File 'jdAllTree.json' không thay đổi. Bỏ qua nạp Database.

```

Hình 0.34: Nạp dữ liệu JSON vào hệ thống

Giai đoạn Tích hợp RAG Pipeline:

- **step_rag_chunking**: Thực hiện đổi chiều từ Cây mục lục (jdAllTree) với các thẻ bên trong từng file HTML chi tiết. Từ đó, bóc tách chính xác từng phần nội dung văn bản thành dạng JSON có các đoạn văn bản và siêu dữ liệu (Metadata).

```

step_rag_chunking 14m 38s

1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_rag_chunking.py
13
14 2026-06-16 00:47:41.163 | INFO | env:<module>:7 - Loading environment variables...
15 2026-06-16 00:47:42.117 | INFO | utils.google_drive:get_or_create_drive_folder:58 - Folder 'step_rag_chunking' đã tồn tại | ID: 1M6pp-hQ03qXbwnNRBn01ZPvMkQYsz1Aa
16 2026-06-16 00:47:42.118 | INFO | __main__:main:129 - Đang tải dữ liệu cây mục lục (jdAllTree.json) vào bộ nhớ...
17 2026-06-16 00:47:42.331 | INFO | __main__:main:134 - Đang tải Metadata (Chủ đề, Đề mục) vào bộ nhớ...
18 2026-06-16 00:47:42.331 | INFO | __main__:main:144 - Bắt đầu xử lý 316 file HTML...
19 2026-06-16 00:47:42.888 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File '2bcac534-554f-47d3-b299-bd9cfc1b92d5.html' không thay đổi (MD5 khớp). Bỏ qua upload.
20 2026-06-16 00:47:42.889 | INFO | __main__:main:181 - Đang parse dữ liệu: 2bcac534-554f-47d3-b299-bd9cfc1b92d5.html
21 2026-06-16 00:47:42.967 | SUCCESS | __main__:main:198 - Đã xử lý bóc tách JSON xong: 2bcac534-554f-47d3-b299-bd9cfc1b92d5.json
22 2026-06-16 00:47:42.971 | WARNING | __main__:main:166 - Không tìm thấy dữ liệu cây cho: d41ae77e-7fa3-4db3-b810-d4019ad6db18 (File HTML có 7 dòng)
23 2026-06-16 00:47:42.976 | WARNING | __main__:main:166 - Không tìm thấy dữ liệu cây cho: e51fdb4d-9c73-44bc-9fae-10c4cde48953 (File HTML có 7 dòng)
24 2026-06-16 00:47:43.434 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File '23e1929c-6151-4f15-9d67-11d4f7964dc8.html' không thay đổi (MD5 khớp). Bỏ qua upload.
25 2026-06-16 00:47:43.434 | INFO | __main__:main:181 - Đang parse dữ liệu: 23e1929c-6151-4f15-9d67-11d4f7964dc8.html
26 2026-06-16 00:47:43.434 | SUCCESS | __main__:main:198 - Đã xử lý bóc tách JSON xong: 23e1929c-6151-4f15-9d67-11d4f7964dc8.json
27 2026-06-16 00:47:44.148 | WARNING | __main__:main:166 - Không tìm thấy dữ liệu cây cho: 467d54d1-b81e-49a0-a066-21e2c9b191fc (File HTML có 7 dòng)
28 2026-06-16 00:47:44.148 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'bc9a9ade-0c9f-43cc-8cc2-8c69773d163e.html' không thay đổi (MD5 khớp). Bỏ qua upload.
29 2026-06-16 00:47:44.605 | INFO | __main__:main:181 - Đang parse dữ liệu: bc9a9ade-0c9f-43cc-8cc2-8c69773d163e.html
30 2026-06-16 00:47:45.300 | SUCCESS | __main__:main:198 - Đã xử lý bóc tách JSON xong: bc9a9ade-0c9f-43cc-8cc2-8c69773d163e.json
31 2026-06-16 00:47:45.663 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'f549c597-2521-4480-bc28-505b06f2e22f.html' không thay đổi (MD5 khớp). Bỏ qua upload.
32 2026-06-16 00:47:45.663 | INFO | __main__:main:181 - Đang parse dữ liệu: f549c597-2521-4480-bc28-505b06f2e22f.html
33 2026-06-16 00:47:51.071 | SUCCESS | __main__:main:198 - Đã xử lý bóc tách JSON xong: f549c597-2521-4480-bc28-505b06f2e22f.json
34 2026-06-16 00:47:51.071 | WARNING | __main__:main:166 - Không tìm thấy dữ liệu cây cho: 4342e880-6160-4d52-85ba-671ad605adae (File HTML có 7 dòng)
35 2026-06-16 00:47:51.071 | WARNING | __main__:main:166 - Không tìm thấy dữ liệu cây cho: 0aeb67ae-9e3e-42c0-830e-33cc254cf384 (File HTML có 7 dòng)
36 2026-06-16 00:47:51.464 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File '176d1e26-86ea-43d0-a30b-0436225de492.html' không thay đổi (MD5 khớp). Bỏ qua upload.
37 2026-06-16 00:47:51.464 | INFO | __main__:main:181 - Đang parse dữ liệu: 176d1e26-86ea-43d0-a30b-0436225de492.html
38 2026-06-16 00:47:51.631 | SUCCESS | __main__:main:198 - Đã xử lý bóc tách JSON xong: 176d1e26-86ea-43d0-a30b-0436225de492.json
39 2026-06-16 00:47:51.636 | WARNING | __main__:main:166 - Không tìm thấy dữ liệu cây cho: 4872e9d9-201e-4ef6-bab9-e49d7e505f0c (File HTML có 7 dòng)
40 2026-06-16 00:47:52.099 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'f0f0c740-cb1f-4013-b5bc-9e14672d586d.html' không thay đổi (MD5 khớp). Bỏ qua upload.

```

Hình 0.35: Bóc tách và chia nhỏ nội dung văn bản theo cấu trúc mục lục

- **step_rag_embedding**: Làm giàu ngữ cảnh bằng cách nối trực tiếp tên Chủ đề và Đề mục vào phần đầu của mỗi đoạn văn bản chunk. Sau đó, nội dung được đưa qua mô hình HuggingFace (keepitreal/vietnamese-sbert) để biến đổi thành các vector và lưu vào CSDL vector Qdrant.

```

step_rag_embedding 1m 34s

1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_rag_embedding.py
13
14 2026-06-16 01:02:18.641 | INFO | env:<module>:7 - Loading environment variables...
15 Loading weights: 0% | 0/199 [00:00<, ?it/s]
16 Loading weights: 100% [██████████] 199/199 [00:00:00, 20000.18it/s]
17 RobertaModel LOAD REPORT from: keepitreal/vietnamese-sbert
18 Key | Status |
19 -----
20 embeddings.position_ids | UNEXPECTED |
21 Notes:
22 - UNEXPECTED: can be ignored when loading from different task/architecture; not ok if you expect identical arch.
23
24 2026-06-16 01:02:39.076 | INFO | rag.vectorstore:<module>:30 - Qdrant collection 'prod_phap_dien_vectors' đã sẵn sàng.
25 2026-06-16 01:02:40.183 | INFO | utils.google_drive:get_or_create_drive_folder:58 - Folder 'step_rag_embedding' đã tồn tại | ID: 17nJm8kl109MpZs_lyw29v--Ee6uphNKR
26 2026-06-16 01:02:40.617 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File '995b0a50-c2a1-45d8-baf6-a0b02c7821cf.json' không thay đổi (MD5 khớp). Bỏ qua upload.
27 2026-06-16 01:02:41.134 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File '2162aa7c-d532-413b-8704-b82973267484.json' không thay đổi (MD5 khớp). Bỏ qua upload.
28 2026-06-16 01:02:41.486 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'ad9817c1-1032-4748-97f7-fd4db42fd04e.json' không thay đổi (MD5 khớp). Bỏ qua upload.
29 2026-06-16 01:02:41.833 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'd0a39796-1eb4-4862-972b-87d5ad87ae2c.json' không thay đổi (MD5 khớp). Bỏ qua upload.
30 2026-06-16 01:02:42.206 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'c78e4b28-0d12-4211-98a5-47fbbd144f7b.json' không thay đổi (MD5 khớp). Bỏ qua upload.
31 2026-06-16 01:02:42.526 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'f549c597-2521-4480-bc28-505b06f2e22f.json' không thay đổi (MD5 khớp). Bỏ qua upload.
32 2026-06-16 01:02:42.918 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File '34030833-66c0-4966-9dff-1f02e805d94f.json' không thay đổi (MD5 khớp). Bỏ qua upload.
33 2026-06-16 01:02:43.269 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File '3284cd8d-f598-48ea-b425-53e118893530.json' không thay đổi (MD5 khớp). Bỏ qua upload.

```

Hình 0.36: Mô hình hóa dữ liệu dạng vector và lưu trữ vào Qdrant

data_pipeline

succeeded 5 days ago in 52s

Search logs

🔄 ⚙️

> ✓ Set up Python

0s

> ✓ Install dependencies

19s

▼ ✓ step_download_zip

25s

1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_download_zip.py

13 2026-06-16 05:00:53.684 | INFO | env:<module>:7 - Loading environment variables...

14 2026-06-16 05:00:54.134 | INFO | __main__:download_file:26 - 📄 Đang tải file từ: <https://phapdien.moj.gov.vn/TraCuuPhapDien/Files/BoPhapDienDienTu.zip>

15 2026-06-16 05:01:15.492 | SUCCESS | __main__:download_file:34 - Tải xong: /home/runner/work/data-pipeline-phapdien/data-pipeline-phapdien/data/step_download_zip/phapdien_latest.zip

16 2026-06-16 05:01:16.017 | INFO | utils.google_drive:get_or_create_drive_folder:58 - Folder 'step_download_zip' đã tồn tại | ID: 1rNG1IIVrHBjWxMbsqQ808Z1xFRi3b5hok

17 2026-06-16 05:01:16.267 | INFO | utils.google_drive:sync_local_file_to_drive:241 - 📁 File 'phapdien_latest.zip' không thay đổi (MD5 khớp). Bỏ qua upload.

18 2026-06-16 05:01:16.267 | SUCCESS | __main__:main:88 - ✓ File ZIP không đổi. Bỏ qua bước giải nén và các step tiếp theo trên GitHub Actions.

🕒 step_extract_json

0s

🕒 step_load_json

0s

🕒 step_rag_chunking

0s

🕒 step_rag_embedding

0s

Hình 0.37: Sơ đồ thu thập dữ liệu chung

Chữ tạm màu đỏ
Đồng thứ hai vẫn có màu đỏ và không bị lỗi ngắt đoạn.
<https://example.com>



Hình 0.38: Logo của Đại học Bách Khoa Hà Nội



Hình 0.39: Logo của Đại học Bách Khoa Hà Nội



Hình 0.40: Logo của Đại học Bách Khoa Hà Nội

- Nội dung mục 1
- Chấm màu xanh

In nghiêng đoạn văn bản

In đậm đoạn văn bản

Ứng dụng trong đồ án

Nội dung block

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.