

MỤC LỤC

0.1 Đường ống dữ liệu	2
0.1.1 Đường ống dữ liệu Văn bản pháp luật	4
0.1.2 Đường ống dữ liệu Pháp Điển	12

0.1 Đường ống dữ liệu

Đường ống dữ liệu bao gồm các chuỗi quy trình xử lý tự động từ một hoặc nhiều nguồn (source) đến một đích đến (destination) để lưu trữ, phân tích hoặc phục vụ cho các ứng dụng khác.


Vì dự án này làm về miền nghiệp vụ pháp luật nên không cần thu thập dữ liệu từ nhiều nguồn khác nhau. Em sử dụng dữ liệu chính thống từ nhà nước là **Văn bản pháp luật** tại địa chỉ <https://vbpl.vn> và dữ liệu **Pháp Điển** tại địa chỉ <https://phapdien.moj.gov.vn/Pages/chi-tiet-bo-phap-dien.aspx>

Giao diện nguồn dữ liệu Văn bản pháp luật




Hình 0.1: Giao diện nguồn dữ liệu Văn bản pháp luật

Giao diện nguồn dữ liệu Pháp Điển



Hình 0.2: Giao diện nguồn dữ liệu Pháp Điển

Sơ đồ thu thập dữ liệu chung



Hình 0.3: Sơ đồ thu thập dữ liệu chung

Tại các bước sẽ sử dụng logic so sánh hash để bỏ qua văn bản không thay đổi nội dung giúp tiết kiệm tài nguyên và thời gian xử lý dữ liệu.

```


> step_run_document_detail 236
> step_load_document_detail 341
> step_extract_document_markdown 379

1 Run deploy run up 2020062004 - c prod - sr run python step_extract_document_markdown.py
15 2020-06-14 10:01:15.771 [INFO] [src=main] - loading environment variables...
16 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
17 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
18 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
19 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
20 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
21 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
22 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
23 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
24 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
25 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
26 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
27 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
28 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
29 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
30 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
31 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
32 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
33 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
34 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
35 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
36 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
37 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
38 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
39 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
40 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
41 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
42 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
43 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
44 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
45 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
46 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
47 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
48 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
49 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
50 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
51 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
52 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
53 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
54 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
55 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
56 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
57 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
58 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
59 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
60 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
61 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
62 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
63 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
64 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
65 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
66 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
67 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
68 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
69 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
70 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
71 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
72 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
73 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
74 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
75 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
76 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
77 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
78 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
79 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
80 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
81 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
82 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
83 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
84 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
85 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
86 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
87 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
88 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
89 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
90 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
91 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
92 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
93 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
94 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
95 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
96 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
97 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
98 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
99 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...
100 2020-06-14 10:01:15.780 [INFO] [src=main] - loading environment variables...

```

Hình 0.4: Sơ đồ thu thập dữ liệu chung

Thư viện dlt (Data Load Tool) là một thư viện Python mã nguồn mở giúp trích xuất dữ liệu từ nhiều nguồn khác nhau và tải chúng vào các tập dữ liệu có cấu trúc rõ ràng.



Hình 0.5: Giao diện nguồn dữ liệu Văn bản pháp luật

Việc sử dụng Data Load Tool hỗ trợ tự động nội suy cấu trúc, kiểu dữ liệu và xử lý mượt mà các cấu trúc dữ liệu lồng nhau hỗ trợ tốt việc thay đổi nếu nguồn dữ liệu có sự thay đổi




Hình 0.6: Data Load Tool tự động thích ứng nguồn dữ liệu có sự thay đổi

0.1.1 Đường ống dữ liệu Văn bản pháp luật


Khi làm việc với bài toán dữ liệu thực tế, việc thu thập dữ liệu có thách thức phụ thuộc vào nguồn dữ liệu. Vào ngày 24/05/2026, nguồn dữ liệu Văn bản pháp luật được thay đổi cả hệ thống, API và giao diện. Do sự thay đổi lớn về dữ liệu thu thập nên hệ thống cần xử lý lại các bước Data pipeline.

Giao diện nguồn dữ liệu Văn bản pháp luật mới:




Hình 0.7: Giao diện trang tìm kiếm của nguồn dữ liệu Văn bản pháp luật mới

Sơ đồ tổng quan Data pipeline Văn bản pháp luật mới:



Hình 0.8: Sơ đồ tổng quan Data pipeline Văn bản pháp luật mới

Các bước thực hiện cũ:



Hình 0.9: Sơ đồ các bước thực hiện của quy trình cũ

Mô tả các bước thực hiện cũ:

Quá trình Data pipeline được chia thành 3 giai đoạn: Thu thập dữ liệu, Tiền xử lý văn bản và Tích hợp RAG Pipeline.

- Giai đoạn Khởi tạo:
 - **step_setup_workflow** cập nhật danh sách và thứ tự các bước (workflow) vào CSDL PostgreSQL.
- Giai đoạn Thu thập Dữ liệu:
 - **step_crawl_document_total** và **step_load_document_total**: thu thập tổng số lượng văn bản pháp luật hiện có trên hệ thống web.

```

118 2026-06-16 01:39:27.288 | DEBUG | utils.request_helper:make_vbpl_page_request:33 - Đang tạo request cho trang 1: https://vbpl-bientap.gateway.moj.gov.vn/api/stdc/public/doc/all
119 (qua proxy)
120 2026-06-16 01:39:27 [scrapy_user_agents.middlewares] DEBUG: Assigned User-Agent Mozilla/5.0 (Windows NT 6.3; WOW64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/47.0.2526.106
121 Safari/537.36
122 2026-06-16 01:39:28 [scrapy.core.downloader.tls] WARNING: Remote certificate is not valid for hostname "toeic.work.gd"; VerificationError(errors=
123 [DNSMismatch(mismatched_id=DNS_ID(hostname=b'toeic.work.gd'))])
124 2026-06-16 01:39:28 [scrapy.core.engine] DEBUG: Crawled (200) <POST https://toeic.work.gd/> (referer: None)
125 2026-06-16 01:39:28.861 | INFO | crawler.spiders.document_total_spider:parse:31 - Tổng số văn bản hiện tại trên API: 168986
126 2026-06-16 01:39:28 [scrapy.core.scrapy] DEBUG: Scraped from <200 https://toeic.work.gd/>
127 ('update_at': '2026-06-16T01:39:28.861172', 'total_count': 168986)
128 2026-06-16 01:39:28 [scrapy.core.engine] INFO: Closing spider (finished)
    
```

Hình 0.10: Thu thập tổng số lượng văn bản pháp luật

- **step_crawl_document_list** và **step_load_document_list**: Dựa vào sự chênh lệch tổng số lượng, tính toán số trang cần quét và thu thập danh sách các **item_id**.

Hình 0.11: Quét danh sách các văn bản pháp luật

Hình 0.12: Nạp danh sách văn bản vào CSDL

- `step_crawl_document_detail` và `step_load_document_detail`: tải toàn bộ mã nguồn HTML trang chi tiết của từng văn bản và Upload các file HTML gốc này lên Google Drive, đồng thời lưu `drive_id` và mã băm MD5 hash vào database để quản lý thay đổi.

Hình 0.13: Tải và lưu trữ mã nguồn HTML trang chi tiết văn bản

- Giai đoạn Tiền xử lý Dữ liệu:
 - **step_extract_document_info**: từ file HTML, bóc tách các siêu dữ liệu quan trọng (Metadata) như: Số hiệu, Cơ quan ban hành, Ngày có hiệu lực, Người ký, v.v. và lưu vào database.
 - **step_extract_document_content**: Làm sạch file HTML, cắt bỏ các phần thừa (header, footer, menu) và chỉ giữ lại phần nội dung (thẻ `div#toanvancontent`).

- **step_extract_document_markdown**: Chuyển đổi file HTML đã làm sạch sang định dạng Markdown.

```

step_extract_document_markdown 43s
1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_extract_document_markdown.py
13 2026-05-31 19:14:11.951 | INFO | env:(module):7 - Loading environment variables...
14 2026-05-31 19:14:18.122 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:113 - Bắt đầu lấy và khóa task cho step_code='step_extract_document_markdown', limit=150
15 2026-05-31 19:14:18.670 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:148 - Đã khóa thành công 39 item(s) cho step_code='step_extract_document_markdown'.
16 2026-05-31 19:14:20.117 | INFO | _main_:document_markdown_resource:112 - Bỏ qua 120791: Văn bản có trạng thái 'Hết hiệu lực toàn bộ'.
17 2026-05-31 19:14:20.117 | INFO | _main_:document_markdown_resource:112 - Đang xử lý Markdown cho item: 120796
18 2026-05-31 19:14:20.118 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/1Pbyep6T1Ta0tkfVYAXS8a824zhdsJE/view
19 2026-05-31 19:14:20.613 | INFO | _main_:document_markdown_resource:134 - Đã lưu file local: /home/runner/work/data-pipeline-vbplnew/data-pipeline-vbplnew/data/step_extract_document_markdown/120796.md
20 2026-05-31 19:14:20.721 | INFO | _main_:document_markdown_resource:151 - Bỏ qua 120796 vì nội dung Markdown không đổi trên Drive.
21 2026-05-31 19:14:20.721 | INFO | _main_:document_markdown_resource:151 - Bỏ qua 120797: Văn bản có trạng thái 'Hết hiệu lực toàn bộ'.
22 2026-05-31 19:14:20.721 | INFO | _main_:document_markdown_resource:151 - Bỏ qua 120799: Văn bản có trạng thái 'Hết hiệu lực toàn bộ'.
23 2026-05-31 19:14:20.721 | INFO | _main_:document_markdown_resource:112 - Đang xử lý Markdown cho item: 120805
24 2026-05-31 19:14:20.721 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/1Qehyr20CYUk0SLu0ggnKms8t9iokrsbY/view
25 2026-05-31 19:14:21.115 | INFO | _main_:document_markdown_resource:134 - Đã lưu file local: /home/runner/work/data-pipeline-vbplnew/data-pipeline-vbplnew/data/step_extract_document_markdown/120805.md
26 2026-05-31 19:14:21.245 | INFO | _main_:document_markdown_resource:151 - Bỏ qua 120805 vì nội dung Markdown không đổi trên Drive.
27 2026-05-31 19:14:21.246 | INFO | _main_:document_markdown_resource:112 - Đang xử lý Markdown cho item: 120806
28 2026-05-31 19:14:21.246 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/1Tmg6Gj6eHtU0sBUy6agL20y6aTsp/view
29 2026-05-31 19:14:21.533 | INFO | _main_:document_markdown_resource:134 - Đã lưu file local: /home/runner/work/data-pipeline-vbplnew/data-pipeline-vbplnew/data/step_extract_document_markdown/120806.md
30 2026-05-31 19:14:21.640 | INFO | _main_:document_markdown_resource:151 - Bỏ qua 120806 vì nội dung Markdown không đổi trên Drive.

```

Hình 0.14: Chuyển đổi nội dung HTML đã làm sạch sang Markdown

- Giai đoạn Tích hợp RAG pipeline:

- **step_rag_summary**: Sử dụng LLM viết một bản tóm tắt ngắn gọn mô tả bức tranh toàn cảnh của văn bản pháp luật đó.

```

step_rag_summary 20m 58s
1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_rag_summary.py
13 2026-06-16 00:40:38.359 | INFO | env:(module):7 - Loading environment variables...
14 2026-06-16 00:40:51.101 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:113 - Bắt đầu lấy và khóa task cho step_code='step_rag_summary', limit=40
15 2026-06-16 00:40:51.801 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:148 - Đã khóa thành công 40 item(s) cho step_code='step_rag_summary'.
16 2026-06-16 00:40:53.801 | INFO | _main_:document_summary_resource:113 - Đang tải và tóm tắt tài liệu: 152024
17 2026-06-16 00:40:53.801 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/1x1zgc3033HMTIaugdPv36wC3ylb9q/view
18 2026-06-16 00:40:54.990 | INFO | rag.llm:invoke_llm_chain:76 - Đang gọi Ollama...
19 2026-06-16 00:42:45.339 | INFO | utils.google_drive:get_or_create_drive_folder:52 - Folder 'step_rag_summary' đã tồn tại | ID: 1Vddgt6huc1ny501tdy8Bh12NF7H15ax
20 2026-06-16 00:42:45.339 | INFO | utils.google_drive:upload_to_drive:77 - Đang upload: 152024.txt (MimeType: text/plain)
21 2026-06-16 00:42:47.233 | SUCCESS | utils.google_drive:upload_to_drive:88 - File uploaded: 152024.txt | ID: 1F01bf1Pu0qQuadyY3Y2Sa0Gt67uWjTt
22 2026-06-16 00:42:47.233 | DEBUG | utils.google_drive:upload_to_drive:89 - Link: https://drive.google.com/file/d/1F01bf1Pu0qQuadyY3Y2Sa0Gt67uWjTt/view
23 2026-06-16 00:42:47.233 | SUCCESS | _main_:document_summary_resource:141 - Đã cập nhật tóm tắt mới cho 152024
24 2026-06-16 00:42:47.386 | INFO | _main_:document_summary_resource:113 - Đang tải và tóm tắt tài liệu: 167147

```

Hình 0.15: Tự động tóm tắt văn bản bằng mô hình LLM

- **step_rag_chunking**: Chạy Semantic Chunking. LLM sẽ dựa vào bản tóm tắt và nội dung chi tiết để quyết định các "điểm cắt" tối ưu, chia nhỏ văn bản thành các đoạn (chunks) sao cho không bị đứt gãy ý nghĩa.

```

step_rag_chunking 8m 40s
1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_rag_chunking.py
13 2026-06-16 01:01:34.856 | INFO | env:(module):7 - Loading environment variables...
14 2026-06-16 01:01:42.939 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:113 - Bắt đầu lấy và khóa task cho step_code='step_rag_chunking', limit=40
15 2026-06-16 01:01:43.435 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:148 - Đã khóa thành công 35 item(s) cho step_code='step_rag_chunking'.
16 2026-06-16 01:01:44.804 | INFO | _main_:document_chunking_resource:192 - Đang tải dữ liệu Markdown & Summary cho tài liệu: 152024
17 2026-06-16 01:01:44.804 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/1x1zgc3033HMTIaugdPv36wC3ylb9q/view
18 2026-06-16 01:01:45.821 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/1F01bf1Pu0qQuadyY3Y2Sa0Gt67uWjTt/view
19 2026-06-16 01:01:46.087 | INFO | _main_:process_and_chunk:190 - Đang gọi LLM để đánh giá semantic chunking...
20 2026-06-16 01:01:46.360 | INFO | rag.llm:invoke_llm_chain:76 - Đang gọi Ollama...
21 2026-06-16 01:01:56.982 | INFO | _main_:process_and_chunk:197 - LLM Response: split_after: 3, 5, 8
22 2026-06-16 01:01:56.983 | INFO | _main_:document_chunking_resource:218 - Đã tạo 4 file chunks trong thư mục: /home/runner/work/data-pipeline-vbplnew/data-pipeline-vbplnew/data/step_rag_chunking/chunk_152024
23 2026-06-16 01:01:56.984 | INFO | _main_:document_chunking_resource:226 - Đang tải file nén lên Google Drive...
24 2026-06-16 01:01:57.660 | INFO | utils.google_drive:get_or_create_drive_folder:52 - Folder 'step_rag_chunking' đã tồn tại | ID: 1uv5PlybM0e2fu6jleQfciV0w-c6lg1-8
25 2026-06-16 01:01:57.662 | INFO | utils.google_drive:upload_to_drive:77 - Đang upload: chunk_zip_152024.zip (MimeType: application/zip)
26 2026-06-16 01:01:59.426 | SUCCESS | utils.google_drive:upload_to_drive:88 - File uploaded: chunk_zip_152024.zip | ID: 13v267MfFbmx1PghI2DfRKFrvsBUp3T3
27 2026-06-16 01:01:59.427 | DEBUG | utils.google_drive:upload_to_drive:89 - Link: https://drive.google.com/file/d/13v267MfFbmx1PghI2DfRKFrvsBUp3T3/view
28 2026-06-16 01:01:59.427 | SUCCESS | _main_:document_chunking_resource:239 - Đã xử lý phân mảnh (chunking) thành công cho 152024 (Drive ID: 13v267MfFbmx1PghI2DfRKFrvsBUp3T3)
29 2026-06-16 01:01:59.567 | INFO | _main_:document_chunking_resource:192 - Đang tải dữ liệu Markdown & Summary cho tài liệu: 167147

```

Hình 0.16: Chia nhỏ văn bản dựa trên ý nghĩa (Semantic Chunking)

- **step_rag_context**: Đây là bước chống mất ngữ cảnh. LLM sẽ sinh ra ngữ cảnh cho từng đoạn chunk nhỏ vừa được cắt, đảm bảo mỗi chunk đều có thể đứng độc lập khi được tìm kiếm.


```

step_rag_context 10m 21s
1 ▶ Run doppler run -p 20206205Tech -c prod -- uv run python step_rag_context.py
13 2026-06-16 01:10:14.851 | INFO | env:(module):7 - Loading environment variables...
14 2026-06-16 01:10:23.079 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:113 - Bắt đầu lấy và khóa task cho step_code='step_rag_context', limit=40
15 2026-06-16 01:10:23.573 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:140 - Đã khóa thành công 30 item(s) cho step_code='step_rag_context'.
16 2026-06-16 01:10:25.545 | INFO | _main_:document_context_resource:141 - Đang tải dữ liệu tóm tắt và chunks cho: 152024
17 2026-06-16 01:10:25.545 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/1FUIHf1PaQoQandY2Y25aGtG7uWjHT/view
18 2026-06-16 01:10:25.820 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/17v267MfHmxtPgZ0R8FchsBUpzT3/view
19 2026-06-16 01:10:26.154 | INFO | _main_:document_context_resource:164 - Bắt đầu tạo ngữ cảnh cho 4 đoạn (chunks)...
20 2026-06-16 01:10:26.154 | INFO | _main_:document_context_resource:181 - Đang sinh ngữ cảnh cho chunk_2.md...
21 2026-06-16 01:10:26.462 | INFO | rag.llm:invoke_llm_chain:76 - Đang gọi Ollama...
22 2026-06-16 01:10:35.235 | INFO | _main_:document_context_resource:181 - Đang sinh ngữ cảnh cho chunk_1.md...
23 2026-06-16 01:10:35.910 | INFO | rag.llm:invoke_llm_chain:76 - Đang gọi Ollama...
24 2026-06-16 01:10:40.466 | INFO | _main_:document_context_resource:181 - Đang sinh ngữ cảnh cho chunk_3.md...
25 2026-06-16 01:10:40.771 | INFO | rag.llm:invoke_llm_chain:76 - Đang gọi Ollama...
26 2026-06-16 01:10:45.681 | INFO | _main_:document_context_resource:181 - Đang sinh ngữ cảnh cho chunk_4.md...
27 2026-06-16 01:10:46.409 | INFO | rag.llm:invoke_llm_chain:76 - Đang gọi Ollama...
28 2026-06-16 01:10:55.977 | INFO | _main_:document_context_resource:206 - Đang tải file Context Zip lên Google Drive...
29 2026-06-16 01:10:56.494 | INFO | utils.google_drive:get_or_create_drive_folder:52 - Folder 'step_rag_context' đã tồn tại | ID: 1vofe41aPMe_zu_y5QhEVQ2iaHwN0c73t
30 2026-06-16 01:10:56.497 | INFO | utils.google_drive:upload_to_drive:77 - Đang upload: contextualized_152024.zip (MimeType: application/zip)
31 2026-06-16 01:10:58.250 | SUCCESS | utils.google_drive:upload_to_drive:88 - File uploaded: contextualized_152024.zip | ID: 18U8M0Og74ybk0puX9qGyGF0Y2-TP1p/view
32 2026-06-16 01:10:58.250 | DEBUG | utils.google_drive:upload_to_drive:89 - Link: https://drive.google.com/file/d/18U8M0Og74ybk0puX9qGyGF0Y2-TP1p/view
33 2026-06-16 01:10:58.250 | SUCCESS | _main_:document_context_resource:219 - Đã xử lý ngữ cảnh thành công cho 152024
34 2026-06-16 01:10:58.557 | INFO | _main_:document_context_resource:141 - Đang tải dữ liệu tóm tắt và chunks cho: 167147
35 2026-06-16 01:10:58.557 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/1xx3ja13g0Q0c0BcrvgvKp1THG8He8I/view
36 2026-06-16 01:10:58.889 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/1BKFgkt0KtX7Sw0Z_BT0bqnl0oRbELAQ/view
37 2026-06-16 01:10:59.191 | INFO | _main_:document_context_resource:164 - Bắt đầu tạo ngữ cảnh cho 1 đoạn (chunks)...
38 2026-06-16 01:10:59.191 | INFO | _main_:document_context_resource:181 - Đang sinh ngữ cảnh cho chunk_1.md...

```

Hình 0.17: Làm giàu ngữ cảnh cho từng đoạn văn bản nhỏ

- **step_rag_embedding**: Sử dụng mô hình HuggingFace (keepitreal/vietnamese-sbert) để biến đổi các đoạn văn bản (đã có ngữ cảnh) thành vector đa chiều và lưu trữ vào VectorDB (Pinecone).


```

step_rag_embedding 55s
1 ▶ Run doppler run -p 20206205Tech -c prod -- uv run python step_rag_embedding.py
13 2026-06-16 01:20:37.004 | INFO | env:(module):7 - Loading environment variables...
14 Loading weights: 0% | 0/199 [00:00<, 21it/s]
15 Loading weights: 100% | 199/199 [00:00:00, 22892.04it/s]
16 2026-06-16 01:20:59.683 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:113 - Bắt đầu lấy và khóa task cho step_code='step_rag_embedding', limit=150
17 2026-06-16 01:21:00.345 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:140 - Đã khóa thành công 26 item(s) cho step_code='step_rag_embedding'.
18 2026-06-16 01:21:00.345 | INFO | _main_:document_embedding_resource:154 - Đang fetch toàn bộ metadata và history hàng loạt cho 26 items...
19 2026-06-16 01:21:07.816 | INFO | _main_:document_embedding_resource:176 - Đang tải và giải nén Chunks (Context) cho tài liệu: 152024
20 2026-06-16 01:21:07.817 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/18U8M0Og74ybk0puX9qGyGF0Y2-TP1p/view
21 2026-06-16 01:21:08.099 | INFO | _main_:document_embedding_resource:191 - Đang tạo vector và lưu vào database cho 4 chunks...
22 2026-06-16 01:21:10.188 | SUCCESS | _main_:document_embedding_resource:256 - Đã lưu 4 vectors vào Vector DB cho: 152024
23 2026-06-16 01:21:10.344 | INFO | _main_:document_embedding_resource:176 - Đang tải và giải nén Chunks (Context) cho tài liệu: 167155
24 2026-06-16 01:21:10.344 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/1s860v0Bq1uzg7p71XYv-fu7C3qkRdP8TP/view
25 2026-06-16 01:21:10.602 | INFO | _main_:document_embedding_resource:191 - Đang tạo vector và lưu vào database cho 1 chunks...

```


Hình 0.18: Nhúng văn bản (Embedding) và lưu vào CSDL Pinecone

Các bước thực hiện mới:



Hình 0.19: Sơ đồ các bước thực hiện của quy trình mới

- Nhờ vào việc nguồn dữ liệu thay đổi sang hệ thống API mới trả về cấu trúc JSON giàu thông tin, hệ thống không còn cần các bước bóc tách thủ công từ mã nguồn HTML phức tạp, giúp tăng tốc độ xử lý và độ chính xác của dữ liệu.
- Hệ thống loại bỏ bước `step_extract_document_info` vì nội dung Metadata chi tiết đã có trong API.
- Hệ thống loại bỏ bước `step_extract_document_content` vì nội dung văn bản đã được API trả trong thông tin `documentContent`.



Hình 0.20: Sơ đồ cấu hình GitHub Actions vận hành workflow mới


Kết quả vận hành thành công đường ống dữ liệu Văn bản pháp luật mới:

```


2026-06-16 01:01:15.216 | SUCCESS | utils.workflow_helper:get_document_state_count_by_workflow:174 - Đã lấy thành công thống kê cho workflow
2026-06-16 01:01:15.222 | DEBUG | utils.workflow_helper:get_document_state_count_by_workflow:201 - ID: 6, Count: 63
2026-06-16 01:01:15.222 | DEBUG | utils.workflow_helper:get_document_state_count_by_workflow:201 - ID: 10, Count: 74798
2026-06-16 01:01:15.222 | DEBUG | utils.workflow_helper:get_document_state_count_by_workflow:201 - ID: 14, Count: 92572
2026-06-16 01:01:18.594 | SUCCESS | utils.workflow_helper:check_status_with_document_count:301 - Đã lấy thành công thống kê document theo status.
2026-06-16 01:01:18.594 | INFO | utils.workflow_helper:check_status_with_document_count:305 - Còn hiệu lực(CHL): 72096
2026-06-16 01:01:18.594 | INFO | utils.workflow_helper:check_status_with_document_count:305 - Không còn phù hợp(KCPH): 255
2026-06-16 01:01:18.594 | INFO | utils.workflow_helper:check_status_with_document_count:305 - Chưa xác định(S): 0
2026-06-16 01:01:18.594 | INFO | utils.workflow_helper:check_status_with_document_count:305 - Hết hiệu lực một phần(HHL1P): 5290
2026-06-16 01:01:18.594 | INFO | utils.workflow_helper:check_status_with_document_count:305 - Ngưng hiệu lực một phần(TNHL1P): 2
2026-06-16 01:01:18.594 | INFO | utils.workflow_helper:check_status_with_document_count:305 - Ngưng hiệu lực(TNHL): 369
2026-06-16 01:01:18.594 | INFO | utils.workflow_helper:check_status_with_document_count:305 - Chưa có hiệu lực(CCHL): 149
2026-06-16 01:01:18.594 | INFO | utils.workflow_helper:check_status_with_document_count:305 - Hết hiệu lực toàn bộ(HHL): 86641

```

Hình 0.21: Kết quả chạy thành công các bước của Data Pipeline mới (Phần 1)




Hình 0.22: Kết quả chạy thành công các bước của Data Pipeline mới (Phần 2)



Hình 0.23: Kết quả chạy thành công các bước của Data Pipeline mới (Phần 3)


0.1.2 Đường ống dữ liệu Pháp Điển

Pháp điển là tập hợp các quy phạm pháp luật đang còn hiệu lực của các văn bản quy phạm pháp luật do cơ quan nhà nước ở trung ương ban hành, từ Thông tư trở lên và trừ Hiến pháp. Sơ đồ tổng quan Data pipeline Pháp Điển




Hình 0.24: Sơ đồ thu thập dữ liệu chung

Tổng quan thông tin file zip



Hình 0.25: Sơ đồ thu thập dữ liệu chung

Kết quả file JSON đã trích xuất




Hình 0.26: Sơ đồ thu thập dữ liệu chung

Kết quả vector được lưu trong vector database



Hình 0.27: Sơ đồ thu thập dữ liệu chung

Các bước thực hiện



Hình 0.28: Sơ đồ thu thập dữ liệu chung

Mô tả các bước thực hiện:

Quá trình Data pipeline được chia thành 3 giai đoạn: Thu thập dữ liệu, Tiền xử lý văn bản và Tích hợp RAG Pipeline.

- Giai đoạn Thu thập Dữ liệu:

- step_download_zip: Tự động tải file nén chứa toàn bộ Bộ pháp điển điện tử (BoPhapDienDienTu.zip) từ nguồn Cổng thông tin điện tử pháp điển. Hệ thống tính toán mã băm (MD5) và đồng bộ với Google Drive để kiểm tra sự thay đổi dữ liệu.

```

1  ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_download_zip.py
13 2026-06-16 00:46:34.238 | INFO | env:module>? - Loading environment variables...
14 2026-06-16 00:46:34.786 | INFO | __main__:download_file:26 - ⚡ Đang tải file từ: https://phapdien.moj.gov.vn/TraCuPhapDien/Files/BoPhapDienDienTu.zip
15 2026-06-16 00:47:21.262 | SUCCESS | __main__:download_file:34 - Tải xong: /home/runner/work/data-pipeline-phapdien/data-pipeline-phapdien/data/step_download_zip/phapdien_latest.zip
16 2026-06-16 00:47:23.852 | INFO | utils.google_drive:get_or_create_drive_folder:70 - ⚡ Tạo folder mới 'step_download_zip' | ID: 1rNG11VH8jao7b5q088Z1xR13b5hok
17 2026-06-16 00:47:23.536 | INFO | utils.google_drive:sync_local_file_to_drive:246 - ⚡ Phát hiện thay đổi (Tạo file mới). Đang đồng bộ 'phapdien_latest.zip' lên Drive...
18 2026-06-16 00:47:23.963 | DEBUG | utils.google_drive:upload_file_to_drive:188 - ⚡ Đang tải file mới 'phapdien_latest.zip'
19 2026-06-16 00:47:26.241 | SUCCESS | utils.google_drive:sync_local_file_to_drive:255 - ⚡ Đồng bộ thành công: phapdien_latest.zip
20 2026-06-16 00:47:26.241 | DEBUG | utils.google_drive:upload_file_to_drive:255 - ⚡ Link: https://drive.google.com/file/d/1K1009H6_t09jC1piAS5Cet1r0tbyA2L2b/view
21 2026-06-16 00:47:26.241 | INFO | __main__:main:66 - ⚡ File ZIP có sự thay đổi. Đang tiến hành giải nén dữ liệu...
22 2026-06-16 00:47:26.728 | SUCCESS | __main__:extract_zip:43 - ⚡ Đã giải nén vào: /home/runner/work/data-pipeline-phapdien/data-pipeline-phapdien/data/step_download_zip/extracted
23 2026-06-16 00:47:26.728 | INFO | __main__:main:76 - ⚡ Đang tạo bản lưu trữ: phapdien_2026_06_16_00_47_26_720835.zip
24 2026-06-16 00:47:26.728 | DEBUG | utils.google_drive:upload_file_to_drive_with_metadata:213 - ⚡ Đang tải file 'phapdien_2026_06_16_00_47_26_720835.zip' lên Drive...

step_extract_json 5s
step_load_json 5s
step_rag_chunking 14m 38s
step_rag_embedding 1m 34s
    
```

Hình 0.29: Tự động tải file nén mới và đồng bộ Google Drive

```

1  ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_download_zip.py
13 2026-06-16 00:00:57.470 | INFO | env:module>? - Loading environment variables...
14 2026-06-16 00:00:57.939 | INFO | __main__:download_file:26 - ⚡ Đang tải file từ: https://phapdien.moj.gov.vn/TraCuPhapDien/Files/BoPhapDienDienTu.zip
15 2026-06-16 00:01:15.819 | SUCCESS | __main__:download_file:34 - Tải xong: /home/runner/work/data-pipeline-phapdien/data-pipeline-phapdien/data/step_download_zip/phapdien_latest.zip
16 2026-06-16 00:01:16.615 | INFO | utils.google_drive:get_or_create_drive_folder:58 - Folder 'step_download_zip' đã tồn tại | ID: 1-s4H4p4uKX3HvQd9p7Gf4aB4759wI-
17 2026-06-16 00:01:17.160 | INFO | utils.google_drive:sync_local_file_to_drive:241 - ⚡ File 'phapdien_latest.zip' không thay đổi (MD5 khớp). Bỏ qua upload.
18 2026-06-16 00:01:17.160 | SUCCESS | __main__:main:88 - ⚡ File ZIP không đổi. Bỏ qua bước giải nén và các step tiếp theo trên Github Actions.

step_extract_json 0s
step_load_json 0s
step_rag_chunking 0s
step_rag_embedding 0s
    
```

Hình 0.30: Kiểm tra mã băm và bỏ qua bước tải nếu không có sự thay đổi dữ liệu

- Giai đoạn Tiền xử lý Dữ liệu:

- step_extract_json và step_load_json: Từ file jsonData.js, tiến hành bóc tách (parse) các biến cấu trúc dữ liệu để lấy danh sách Chủ đề (jdChuDe), Đề mục (jdDeMuc) và Cây mục lục (jdAllTree), sau đó xuất ra định dạng JSON.

```

step_extract_json
1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_extract_json.py
13
14 2026-06-16 00:47:29.646 | INFO | env:(module):7 - Loading environment variables...
15 2026-06-16 00:47:30.408 | INFO | utils.google_drive:get_or_create_drive_folder:58 - Folder 'step_extract_json' đã tồn tại | ID: 1lQ10eY22yhKuy88Pnm4f_S10hddn3
16 2026-06-16 00:47:30.901 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'jsonData.js' không thay đổi (MDS khớp). Bỏ qua upload.
17 2026-06-16 00:47:30.901 | INFO | __main__:main:64 - Bắt đầu trích xuất các biến dữ liệu từ file JS...
18 2026-06-16 00:47:34.156 | SUCCESS | __main__:main:81 - Đã trích xuất và lưu file local: jdChuDe.json
19 2026-06-16 00:47:34.158 | SUCCESS | __main__:main:81 - Đã trích xuất và lưu file local: jdDeHuc.json
20 2026-06-16 00:47:34.585 | SUCCESS | __main__:main:81 - Đã trích xuất và lưu file local: jdAllTree.json

```

Hình 0.31: Bóc tách biến cấu trúc dữ liệu và xuất ra file JSON

```

step_load_json
1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_load_json.py
13
14 2026-06-16 00:47:36.584 | INFO | env:(module):7 - Loading environment variables...
15 2026-06-16 00:47:36.728 | INFO | __main__:main:25 - Khởi tạo tiến trình Load JSON...
16 2026-06-16 00:47:37.556 | INFO | utils.google_drive:get_or_create_drive_folder:58 - Folder 'step_load_json' đã tồn tại | ID: 1C5-HV_6Q_sx1fe_2HAEDDCb32xesqth
17 2026-06-16 00:47:37.615 | INFO | __main__:main:45 - Kiểm tra thay đổi file: jdChuDe.json
18 2026-06-16 00:47:38.147 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'jdChuDe.json' không thay đổi (MDS khớp). Bỏ qua upload.
19 2026-06-16 00:47:38.147 | INFO | __main__:main:52 - File 'jdChuDe.json' không thay đổi. Bỏ qua nạp Database.
20 2026-06-16 00:47:38.147 | INFO | __main__:main:45 - Kiểm tra thay đổi file: jdDeHuc.json
21 2026-06-16 00:47:38.622 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'jdDeHuc.json' không thay đổi (MDS khớp). Bỏ qua upload.
22 2026-06-16 00:47:38.622 | INFO | __main__:main:52 - File 'jdDeHuc.json' không thay đổi. Bỏ qua nạp Database.
23 2026-06-16 00:47:39.072 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'jdAllTree.json' không thay đổi (MDS khớp). Bỏ qua upload.
24 2026-06-16 00:47:39.072 | INFO | __main__:main:52 - File 'jdAllTree.json' không thay đổi. Bỏ qua nạp Database.

```

Hình 0.32: Nạp dữ liệu JSON vào hệ thống

- Giai đoạn Tích hợp RAG Pipeline:

- step_rag_chunking: Thực hiện đối chiếu từ Cây mục lục (jdAllTree) với các thẻ bên trong từng file HTML chi tiết. Từ đó, bóc tách chính xác từng phần nội dung văn bản thành dạng JSON có các đoạn văn bản và siêu dữ liệu (Metadata).

```

step_rag_chunking
1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_rag_chunking.py
13
14 2026-06-16 00:47:41.163 | INFO | env:(module):7 - Loading environment variables...
15 2026-06-16 00:47:42.117 | INFO | utils.google_drive:get_or_create_drive_folder:58 - Folder 'step_rag_chunking' đã tồn tại | ID: 1M6pp-HQ03qKhWNR8n01ZPVmkQys21Aa
16 2026-06-16 00:47:42.118 | INFO | __main__:main:129 - Đang tải dữ liệu cây mục lục (jdAllTree.json) vào bộ nhớ...
17 2026-06-16 00:47:42.330 | INFO | __main__:main:134 - Đang tải Metadata (Chủ đề, Đề mục) vào bộ nhớ...
18 2026-06-16 00:47:42.331 | INFO | __main__:main:144 - Bắt đầu xử lý 316 file HTML...
19 2026-06-16 00:47:42.888 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File '2bcac534-554f-47d3-b299-bd9cfc1b92d5.html' không thay đổi (MDS khớp). Bỏ qua upload.
20 2026-06-16 00:47:42.889 | INFO | __main__:main:181 - Đang parse dữ liệu: 2bcac534-554f-47d3-b299-bd9cfc1b92d5.html
21 2026-06-16 00:47:42.967 | SUCCESS | __main__:main:190 - Đã xử lý bóc tách JSON xong: 2bcac534-554f-47d3-b299-bd9cfc1b92d5.json
22 2026-06-16 00:47:42.971 | WARNING | __main__:main:166 - Không tìm thấy dữ liệu cây cho: d41ae77e-7fa3-4db3-b810-44019ad6db18 (File HTML có 7 dòng)
23 2026-06-16 00:47:42.976 | WARNING | __main__:main:166 - Không tìm thấy dữ liệu cây cho: e51fdb4d-9c73-44b3-9fae-10c4de48953 (File HTML có 7 dòng)
24 2026-06-16 00:47:43.434 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File '23e1929c-6151-4f15-9d67-11d4f7964dc8.html' không thay đổi (MDS khớp). Bỏ qua upload.
25 2026-06-16 00:47:43.434 | INFO | __main__:main:181 - Đang parse dữ liệu: 23e1929c-6151-4f15-9d67-11d4f7964dc8.html
26 2026-06-16 00:47:44.143 | SUCCESS | __main__:main:190 - Đã xử lý bóc tách JSON xong: 23e1929c-6151-4f15-9d67-11d4f7964dc8.json
27 2026-06-16 00:47:44.148 | WARNING | __main__:main:166 - Không tìm thấy dữ liệu cây cho: 467d5d41-b81e-49a0-a866-21a2cb101fc (File HTML có 7 dòng)
28 2026-06-16 00:47:44.405 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'bc9a9ade-0c9f-43cc-8cc2-8c69773d163e.html' không thay đổi (MDS khớp). Bỏ qua upload.
29 2026-06-16 00:47:44.405 | INFO | __main__:main:181 - Đang parse dữ liệu: bc9a9ade-0c9f-43cc-8cc2-8c69773d163e.html
30 2026-06-16 00:47:45.308 | SUCCESS | __main__:main:190 - Đã xử lý bóc tách JSON xong: bc9a9ade-0c9f-43cc-8cc2-8c69773d163e.json
31 2026-06-16 00:47:45.663 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'f549c597-2521-4480-bc28-505b06f2e22f.html' không thay đổi (MDS khớp). Bỏ qua upload.
32 2026-06-16 00:47:45.663 | INFO | __main__:main:181 - Đang parse dữ liệu: f549c597-2521-4480-bc28-505b06f2e22f.html
33 2026-06-16 00:47:51.067 | SUCCESS | __main__:main:190 - Đã xử lý bóc tách JSON xong: f549c597-2521-4480-bc28-505b06f2e22f.json
34 2026-06-16 00:47:51.071 | WARNING | __main__:main:166 - Không tìm thấy dữ liệu cây cho: 4342e880-6160-4d52-85ba-671ad605ad4e (File HTML có 7 dòng)
35 2026-06-16 00:47:51.464 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File '176d1e26-86ea-43d0-a30b-0436225de492.html' không thay đổi (MDS khớp). Bỏ qua upload.
36 2026-06-16 00:47:51.464 | INFO | __main__:main:181 - Đang parse dữ liệu: 176d1e26-86ea-43d0-a30b-0436225de492.html
37 2026-06-16 00:47:51.631 | SUCCESS | __main__:main:190 - Đã xử lý bóc tách JSON xong: 176d1e26-86ea-43d0-a30b-0436225de492.json
38 2026-06-16 00:47:51.636 | WARNING | __main__:main:166 - Không tìm thấy dữ liệu cây cho: 4872e9d9-201e-4ef6-bab9-e49d7e505f0c (File HTML có 7 dòng)
39 2026-06-16 00:47:52.099 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'f0f0c740-b1cf-4013-b5bc-9e14672d586d.html' không thay đổi (MDS khớp). Bỏ qua upload.

```

Hình 0.33: Bóc tách và chia nhỏ nội dung văn bản theo cấu trúc mục lục

- step_rag_embedding: Làm giàu ngữ cảnh bằng cách nối trực tiếp tên Chủ đề và Đề mục vào phần đầu của mỗi đoạn văn bản chunk. Sau đó, nội dung được đưa qua mô hình HuggingFace (keepitreal/vietnamese-sbert) để biến đổi thành các vector và lưu vào CSDL vector Qdrant.

```
step_rag_embedding 1m 34s
1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_rag_embedding.py
13 2026-06-16 01:02:18.641 | INFO | env:(module):7 - Loading environment variables...
15 Loading weights: 0% | 0/199 [00:00:00, 11it/s]
16 Loading weights: 100% | 199/199 [00:00:00:00, 20090.18it/s]
17 RobertModel LOAD REPORT from: keepitreal/vietnamese-sbert
18 Key | Status |
19 -----
20 embeddings.position_ids | UNEXPECTED |
21 Notes:
22 - UNEXPECTED: can be ignored when loading from different task/architecture; not ok if you expect identical arch.
23 rag.vectorstore:(module):30 - Qdrant collection 'prod_phap_dien_vectors' đã sẵn sàng.
24 2026-06-16 01:02:39.876 | INFO | utils.google_drive:get_or_create_drive_folder:58 - Folder 'step_rag_embedding' đã tồn tại | ID: 17n3e8d1l099p7s_lyu29v-_Fe6lqMNRK
25 2026-06-16 01:02:40.183 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File '995b0a50-c2a1-45d8-baf6-a0b02c7821cf.json' không thay đổi (MOS khớp). Bỏ qua upload.
26 2026-06-16 01:02:40.617 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File '2162aa7c-d532-413b-8704-b82973267484.json' không thay đổi (MOS khớp). Bỏ qua upload.
27 2026-06-16 01:02:41.134 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'ad9817c1-1032-4748-97f7-fd4db42fd04e.json' không thay đổi (MOS khớp). Bỏ qua upload.
28 2026-06-16 01:02:41.486 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'd8a39796-1eb4-4862-972b-87d5ad87ae2c.json' không thay đổi (MOS khớp). Bỏ qua upload.
29 2026-06-16 01:02:41.833 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'c78e4b28-0d12-4211-98a5-47fbd144f7b.json' không thay đổi (MOS khớp). Bỏ qua upload.
30 2026-06-16 01:02:42.206 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'f549c597-2521-4480-bc28-505b66f2e22f.json' không thay đổi (MOS khớp). Bỏ qua upload.
31 2026-06-16 01:02:42.526 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File '34030833-66c0-4966-9dff-1f02e805d94f.json' không thay đổi (MOS khớp). Bỏ qua upload.
32 2026-06-16 01:02:42.918 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File '3284cd8d-f598-48ea-b425-53e118893530.json' không thay đổi (MOS khớp). Bỏ qua upload.
33 2026-06-16 01:02:43.269 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File '3284cd8d-f598-48ea-b425-53e118893530.json' không thay đổi (MOS khớp). Bỏ qua upload.
```

Hình 0.34: Mô hình hóa dữ liệu dạng vector và lưu trữ vào Qdrant

```
data_pipeline
succeeded 5 days ago in 52s
Q Search logs
> Set up Python 0s
> Install dependencies 23s
> step_download_zip 25s
1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_download_zip.py
13 2026-06-16 01:00:33.080 | INFO | env:(module):7 - Loading environment variables...
14 2026-06-16 01:00:54.134 | INFO | __main__:download_file:20 - Đang tải file từ: https://phapdien-mj1.gcp.us/TracCuPhapDien/Files/PhapDienServiceData.zip
15 2026-06-16 01:01:15.493 | SUCCESS | __main__:download_file:24 - File xong: /home/runner/work/data-pipeline-phapdien/step_pipeline-phapdien/data/step_download_zip/phapdien_test.zip
16 2026-06-16 01:01:16.027 | INFO | utils.google_drive:get_or_create_drive_folder:58 - Folder 'step_download_zip' đã tồn tại | ID: 17n3e8d1l099p7s_lyu29v-_Fe6lqMNRK
17 2026-06-16 01:01:16.267 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'phapdien_test.zip' không thay đổi (MOS khớp). Bỏ qua upload.
18 2026-06-16 01:01:16.267 | SUCCESS | __main__:main:88 - File ZIP không đổi. Bỏ qua bước giải nén và các step tiếp theo trên Github Actions.
○ step_extract_json 0s
○ step_load_json 0s
○ step_rag_chunking 0s
○ step_rag_embedding 0s
```

Hình 0.35: Sơ đồ thu thập dữ liệu chung

Chào mừng đến với data-pipeline-phapdien-service (production)

- Đăng nhập: Google
- Database
- Local
- Doc
- Docx
- Pdf
- Word
- Xlsx
- Zip

Servers	
data-pipeline-phapdien-service	
Authorize	
phapdien	
GET	/phapdien/chu-de Get Chu De
GET	/phapdien/de-muc Get De Mu
GET	/phapdien/summary Get Summary

Hình 0.36: swagger

workflows	
GET	/workflows List Workflows
GET	/workflows/summary Get Pipeline Summary
documents	
GET	/documents/total Get Document Total
GET	/documents/status Get Document Status Report
GET	/documents/recent Get Recent Documents
GET	/documents/issue-date Get Issue Date Report
GET	/documents/info Get Document Info
GET	/documents/doc-types Get Doc Types
GET	/documents/eff-statuses Get EF Statuses
GET	/documents/majors Get Majors

Hình 0.37: swagger