



0.0.1 Đường ống dữ liệu Văn bản pháp luật

Khi làm việc với bài toán dữ liệu thực tế, việc thu thập dữ liệu có thách thức phụ thuộc vào nguồn dữ liệu. Vào ngày 24/05/2026, nguồn dữ liệu Văn bản pháp luật được thay đổi cả hệ thống, API và giao diện. Do sự thay đổi lớn về dữ liệu thu thập nên hệ thống cần xử lý lại toàn bộ các bước trong luồng dữ liệu.




Hình 0.1: Giao diện trang tìm kiếm của nguồn dữ liệu Văn bản pháp luật mới



Hình 0.2: Sơ đồ tổng quan luồng dữ liệu Văn bản pháp luật mới

Các bước thực hiện cũ:



Hình 0.3: Sơ đồ các bước thực hiện của quy trình cũ

Mô tả các bước thực hiện cũ:

Quá trình luồng dữ liệu được chia thành 3 giai đoạn: Thu thập dữ liệu, Tiền xử lý văn bản và Tích hợp quy trình RAG.

Giai đoạn Khởi tạo:

- **step_setup_workflow** cập nhật danh sách và thứ tự các bước (workflow) vào CSDL PostgreSQL.

Giai đoạn Thu thập Dữ liệu:

- **step_crawl_document_total** và **step_load_document_total**: thu thập tổng số lượng văn bản pháp luật hiện có trên hệ thống web.

```

step_crawl_document_total
118 2026-06-16 01:39:27.288 | DEBUG | utils.request_helper:make_vbpl_page_request:33 - Đang tạo request cho trang 1: https://vbpl-bientap.gateway.moj.gov.vn/api/qtdc/public/doc/all (qua proxy)
119 2026-06-16 01:39:27 [scrapy_user_agents.middlewares] DEBUG: Assigned User-Agent Mozilla/5.0 (Windows NT 6.3; WOW64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/47.0.2526.106 Safari/537.36
121 2026-06-16 01:39:28 [scrapy.core.downloader.tls] WARNING: Remote certificate is not valid for hostname "toelc.work.gd"; VerificationError(errors=[DNSMismatch(mismatched_id=DNS_ID(hostname=b'toelc.work.gd'))])
122 2026-06-16 01:39:28 [scrapy.core.engine] DEBUG: Crawled (200) <POST https://toelc.work.gd/> (referer: None)
123 2026-06-16 01:39:28.861 | INFO | crawler.spiders.document_total_spider:parse:31 - Tổng số văn bản hiện tại trên API: 168986
124 2026-06-16 01:39:28 [scrapy.core.scrapy] DEBUG: Scraped from <200 https://toelc.work.gd/>
125 {'update_at': '2026-06-16T01:39:28.86172', 'total_count': 168986}
126 2026-06-16 01:39:28 [scrapy.core.engine] INFO: Closing spider (finished)

```

Hình 0.4: Thu thập tổng số lượng văn bản pháp luật

- **step_crawl_document_list** và **step_load_document_list**: Dựa vào sự chênh lệch tổng số lượng, tính toán số trang cần quét và thu thập danh sách các **item_id**.

```

step_crawl_document_list
120 2026-06-16 01:35:30.530 | DEBUG | utils.request_helper:make_vbpl_page_request:33 - Đang tạo request cho trang 1: https://vbpl-bientap.gateway.moj.gov.vn/api/qtdc/public/doc/all (qua proxy)
121 2026-06-16 01:35:30 [scrapy_user_agents.middlewares] DEBUG: Assigned User-Agent Mozilla/5.0 (Windows NT 6.3; WOW64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/51.0.2704.103 Safari/537.36
123 2026-06-16 01:35:31 [scrapy.core.downloader.tls] WARNING: Remote certificate is not valid for hostname "hust.work.gd"; VerificationError(errors=[DNSMismatch(mismatched_id=DNS_ID(hostname=b'hust.work.gd'))])
124 2026-06-16 01:35:32 [scrapy.core.engine] DEBUG: Crawled (200) <POST https://hust.work.gd/> (referer: None)
125 {'id': 'c16a3700-67d3-11f1-a2ee-eb7a80c8d5d', 'title': 'Thông tư Quy định phân cấp thẩm quyền của Bộ trưởng Bộ Xây dựng trong lĩnh vực quản lý, sử dụng tài sản công; đầu tư xây dựng, mua sắm, sửa chữa, cải tạo, nâng cấp tài sản, trang thiết bị sử dụng kinh phí chi thường xuyên ngân sách nhà nước', 'docnum': '27/2026/TT-BXD', 'doctype': {'id': '178c63a9-73ff-4fd4-9d91-18d690520890', 'name': 'Thông tư', 'code': 'TT', 'parentCode': 'VBQPPL', 'parentName': '', 'issueDate': '2026-06-05T00:00:00', 'efffrom': '2026-06-01T00:00:00', 'effto': None, 'publicDate': None, 'updatedAt': None, 'effStatus': {'id': 'dc434caf-9223-40de-a759-d4f2e3f7b06f', 'code': 'CCHL', 'name': 'Chưa có hiệu lực', 'parentCode': None, 'parentName': None, 'documentMajors': None, 'documentMajors': None, 'isnew': True, 'documentRelatedList': [{'id': 'c17f1e90-67d3-11f1-80ee-f3e70ada2a82', 'fileName': '', 'relatedType': '', 'fileTitle': '', 'fileOrder': None}], {'id': 'c1825200-67d3-11f1-af6c-1fb6b08d954a', 'fileName': '', 'relatedType': '', 'fileTitle': '', 'fileOrder': None}], {'id': 'c1825200-67d3-11f1-af6c-1fb6b08d954a', 'fileName': '', 'relatedType': '', 'fileTitle': '', 'fileOrder': None}], {'id': 'c1825200-67d3-11f1-af6c-1fb6b08d954a', 'fileName': '', 'relatedType': '', 'fileTitle': '', 'fileOrder': None}], 'sourceD
226 2026-06-16 01:35:32 [scrapy_user_agents.middlewares] DEBUG: Assigned User-Agent Mozilla/5.0 (Windows NT 6.1; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/58.0.3029.110 Safari/537.36
125 2026-06-16 01:35:32.400 | DEBUG | utils.request_helper:make_vbpl_page_request:33 - Đang tạo request cho trang 2: https://vbpl-bientap.gateway.moj.gov.vn/api/qtdc/public/doc/all (qua proxy)
126 2026-06-16 01:35:32 [scrapy.core.scrapy] DEBUG: Scraped from <200 https://hust.work.gd/>
127 {'id': '13016f10-6866-11f1-8aba-af16f7deb120', 'title': 'Quyết định số 2878/QĐ-UBND Về việc bãi bỏ các văn bản quy phạm pháp luật của Ủy ban nhân dân tỉnh Lâm Đồng (trước sáp nhập); Ủy ban nhân dân tỉnh Bình Thuận (trước sáp nhập) và Ủy ban nhân dân tỉnh Đắk Nông (trước sáp nhập) ban hành thuộc lĩnh vực vận tải', 'docnum': '2878/QĐ-UBND', 'doctype': {'id': '0a5362e8-cdca-436e-96cd-979598df3b16', 'name': 'Quyết định', 'code': 'QĐ', 'parentCode': 'VBQPPL', 'parentName': '', 'issueDate': '2026-06-12T00:00:00', 'efffrom': '2026-06-12T00:00:00', 'effto': None, 'publicDate': None, 'updatedAt': None, 'effStatus': {'id': '1419f6be-4a15-44a7-97ac-ea042770a514', 'code': 'CHL', 'name': 'Còn hiệu lực', 'parentCode': None, 'parentName': None, 'documentMajors': None, 'documentMajors': None, 'isnew': True, 'documentRelatedList': [{'id': '13226400-6866-11f1-ba8b-f57c5703ad55', 'fileName': '', 'relatedType': '', 'fileTitle': '', 'fileOrder': None}], {'id': '1329dea0-6866-11f1-b535-7591600ceaa4', 'fileName': '', 'relatedType': '', 'fileTitle': ''}, 'fileTitle': '', 'fileOrder': None}], {'id': '1329dea0-6866-11f1-b535-7591600ceaa4', 'fileName': '', 'relatedType': '', 'fileTitle': ''}, 'fileTitle': '', 'fileOrder': None}], 'sourceD
128 2026-06-16 01:35:32 [scrapy.core.scrapy] DEBUG: Scraped from <200 https://hust.work.gd/>
129 {'id': 'a2eff550-6885-11f1-8f04-5508af3c928', 'title': 'Quyết định Ban hành quy định quản lý nghĩa trang và cơ sở hỏa táng trên địa bàn thành phố Đồng Nai', 'docnum': '13/2026/QĐ-UBND', 'doctype': {'id': '0a5362e8-cdca-436e-96cd-979598df3b16', 'name': 'Quyết định', 'code': 'QĐ', 'parentCode': 'VBQPPL', 'parentName': '', 'issueDate': '2026-06-11T00:00:00', 'efffrom': '2026-06-11T00:00:00', 'effto': None, 'publicDate': None, 'updatedAt': None, 'effStatus': {'id': 'dc434caf-9223-40de-a759-d4f2e3f7b06f', 'code': 'CCHL', 'name': 'Chưa có hiệu lực', 'parentCode': None, 'parentName': None, 'documentMajors': None, 'documentMajors': None, 'isnew': True, 'documentRelatedList': [{'id': 'a33eb190-6885-11f1-befb-299af169672', 'fileName': '', 'relatedType': '', 'fileTitle': '', 'fileOrder': None}], {'id': '50f59fab-6886-11f1-86fd-a9288f8f5e6a', 'fileName': '', 'relatedType': '', 'fileTitle': '', 'fileOrder': None}], {'id': '50f59fab-6886-11f1-86fd-a9288f8f5e6a', 'fileName': '', 'relatedType': '', 'fileTitle': '', 'fileOrder': None}], 'sourceD
130 2026-06-16 01:35:32 [scrapy.core.scrapy] DEBUG: Scraped from <200 https://hust.work.gd/>

```

Hình 0.5: Quét danh sách các văn bản pháp luật

```

step_load_document_list
1 ▶ run doppler run -p 20206205tech -c prod -- uv run python step_load_document_list.py
13
14 2026-06-16 01:35:34.542 | INFO | env:module:7 - Loading environment variables...
15 2026-06-16 01:35:34.745 | INFO | __main__:main:146 - Bắt đầu load dữ liệu với BATCH_SIZE = 500...
16 2026-06-16 01:35:34.746 | INFO | __main__:main:158 - Đang chuẩn bị load batch 1 (50 records) vào Database...
17 Warning: 0 01:35:39,279 [WARNING] [139752578222976] [dti/validate.py/verify_normalized_table:113] In schema 'step_load_document_list': The following columns in table 'documents' did not receive any data during this load and therefore could not have their types inferred:
18 - public_date
19 Unless type hints are provided, these columns will not be materialized in the destination.
20 One way to provide type hints is to use the 'columns' argument in the '@dti.resource' decorator. For example:
21 @dti.resource(columns={'public_date': {'data_type': 'text'}})
22 2026-06-16 01:35:51.394 | INFO | __main__:main:171 - Hoàn thành batch 1.
23 2026-06-16 01:35:51.394 | INFO | __main__:main:178 - Hoàn thành Load tổng cộng 50 records vào Database.
24 2026-06-16 01:36:04.170 | INFO | utils.workflow_helper:log_workflow_state:94 - Đã lưu trạng thái workflow_id=5: item_ids=['13016f10-6866-11f1-8aba-af16f7deb120', 'a2eff550-6885-11f1-8f04-5508af3c928', '095db1b0-673c-11f1-b50e-e18f608ff0da', '324cc180-6866-11f1-8434-814c637e19b2', '6351e0d0-663b-11f1-b8f6-9f6b2adf723c', 'c9f60430-64a9-11f1-b2be-0f8f3567932b', '383a0c70-6865-11f1-9039-c357c1f98910', 'e22d5500-67d6-11f1-abdf-471fb7043657', '5277dd10-662b-11f1-992a-9d39ff53c63f', 'b13173f0-67d1-11f1-8901-494d6183c51c', '72a096d0-6852-11f1-9982-25409bae452e', 'd7b3fda0-6537-11f1-af04-316947cd6606', '23fcf080-6534-11f1-9428-37e1a0df0828', 'ee4f7cf0-685d-11f1-975e-7989390c14bd', '127f8e80-685e-11f1-b019-a3a9eddff5e2', '2a6aacb0-654c-11f1-9fa9-a588f6bb04a', 'e43f5500-6579-11f1-a777-67a3272da19f', '85d5cc40-657b-11f1-89c6-b72a9de9e87b', '7c421070-647d-11f1-be2c-c360560a1d60', '03f4d990-653b-11f1-94d8-e50a9675a59c', 'c80912f0-6546-11f1-9dff-bd57c051b866', '96c6e4d0-

```

Hình 0.6: Nạp danh sách văn bản vào CSDL

- **step_crawl_document_detail** và **step_load_document_detail**: tải toàn bộ mã nguồn HTML trang chi tiết của từng văn bản và Upload các file HTML gốc này lên Google Drive, đồng thời lưu `drive_id` và mã băm MD5 hash vào database để quản lý thay đổi.

```

> step_crawl_document_detail
v step_load_document_detail

1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_load_document_detail.py
13 2026-05-31 19:13:19.771 | INFO | env:<module>:7 - Loading environment variables...
14 2026-05-31 19:13:20.002 | INFO | __main__:main:305 - Bắt đầu load dữ liệu với BATCH_SIZE = 100...
15 2026-05-31 19:13:22.640 | INFO | __main__:process_drive_upload:91 - File không đổi trên Drive, bỏ qua upload: 187003
16 2026-05-31 19:13:22.771 | INFO | __main__:process_drive_upload:91 - File không đổi trên Drive, bỏ qua upload: 186982
17 2026-05-31 19:13:22.922 | INFO | __main__:process_drive_upload:91 - File không đổi trên Drive, bỏ qua upload: 186988
18 2026-05-31 19:13:23.074 | INFO | __main__:process_drive_upload:91 - File không đổi trên Drive, bỏ qua upload: 186989
19 2026-05-31 19:13:23.181 | INFO | __main__:process_drive_upload:91 - File không đổi trên Drive, bỏ qua upload: 187018
20 2026-05-31 19:13:23.303 | INFO | __main__:process_drive_upload:91 - File không đổi trên Drive, bỏ qua upload: vbpqta_2408
21 2026-05-31 19:13:23.409 | INFO | __main__:process_drive_upload:91 - File không đổi trên Drive, bỏ qua upload: 136593
22 2026-05-31 19:13:23.516 | INFO | __main__:process_drive_upload:91 - File không đổi trên Drive, bỏ qua upload: 180011
23 2026-05-31 19:13:23.621 | INFO | __main__:process_drive_upload:91 - File không đổi trên Drive, bỏ qua upload: 180039
24 2026-05-31 19:13:23.827 | INFO | __main__:process_drive_upload:91 - File không đổi trên Drive, bỏ qua upload: 120791
25 2026-05-31 19:13:23.939 | INFO | __main__:process_drive_upload:91 - File không đổi trên Drive, bỏ qua upload: 120797
26 2026-05-31 19:13:24.125 | INFO | __main__:process_drive_upload:91 - File không đổi trên Drive, bỏ qua upload: 187004

```

Hình 0.7: Tải và lưu trữ mã nguồn HTML trang chi tiết văn bản

Giai đoạn Tiền xử lý Dữ liệu:

- **step_extract_document_info**: từ file HTML, bóc tách các siêu dữ liệu quan trọng (Meta-data) như: Số hiệu, Cơ quan ban hành, Ngày có hiệu lực, Người ký, v.v. và lưu vào database.
- **step_extract_document_content**: Làm sạch file HTML, cắt bỏ các phần thừa (header, footer, menu) và chỉ giữ lại phần nội dung (thẻ `div#toanvancontent`).
- **step_extract_document_markdown**: Chuyển đổi file HTML đã làm sạch sang định dạng Markdown.

```

step_extract_document_markdown 435

1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_extract_document_markdown.py
13 2026-05-31 19:14:11.951 | INFO | env:<module>:7 - Loading environment variables...
14 2026-05-31 19:14:18.122 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:113 - Bắt đầu lấy và khóa task cho step_code='step_extract_document_markdown', limit=150
15 2026-05-31 19:14:18.670 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:148 - Đã khóa thành công 39 item(s) cho step_code='step_extract_document_markdown'.
16 2026-05-31 19:14:20.117 | INFO | __main__:document_markdown_resource:94 - Bỏ qua 120791: Văn bản có trạng thái 'Hết hiệu lực toàn bộ'.
17 2026-05-31 19:14:20.117 | INFO | __main__:document_markdown_resource:112 - Đang xử lý Markdown cho item: 120796
18 2026-05-31 19:14:20.118 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/1Phyep6eT1aDtkfivYAX50a824zh5JE/view
19 2026-05-31 19:14:20.613 | INFO | __main__:document_markdown_resource:134 - Đã lưu file local: /home/runner/work/data-pipeline-vbp1new/data-pipeline-vbp1new/data/step_extract_document_markdown/120796.md
20 2026-05-31 19:14:20.721 | INFO | __main__:document_markdown_resource:151 - Bỏ qua 120796 vì nội dung Markdown không đổi trên Drive.
21 2026-05-31 19:14:20.721 | INFO | __main__:document_markdown_resource:94 - Bỏ qua 120797: Văn bản có trạng thái 'Hết hiệu lực toàn bộ'.
22 2026-05-31 19:14:20.721 | INFO | __main__:document_markdown_resource:94 - Bỏ qua 120799: Văn bản có trạng thái 'Hết hiệu lực toàn bộ'.
23 2026-05-31 19:14:20.721 | INFO | __main__:document_markdown_resource:112 - Đang xử lý Markdown cho item: 120805
24 2026-05-31 19:14:20.721 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/1Qebv20CvY2k05Lm8qNlnSti0KrsbV/view
25 2026-05-31 19:14:21.115 | INFO | __main__:document_markdown_resource:134 - Đã lưu file local: /home/runner/work/data-pipeline-vbp1new/data-pipeline-vbp1new/data/step_extract_document_markdown/120805.md
26 2026-05-31 19:14:21.245 | INFO | __main__:document_markdown_resource:151 - Bỏ qua 120805 vì nội dung Markdown không đổi trên Drive.
27 2026-05-31 19:14:21.246 | INFO | __main__:document_markdown_resource:112 - Đang xử lý Markdown cho item: 120806
28 2026-05-31 19:14:21.246 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/1Tmg6jG6HtU0sBUYGaegL20y6aTsp/view
29 2026-05-31 19:14:21.533 | INFO | __main__:document_markdown_resource:134 - Đã lưu file local: /home/runner/work/data-pipeline-vbp1new/data-pipeline-vbp1new/data/step_extract_document_markdown/120806.md
30 2026-05-31 19:14:21.640 | INFO | __main__:document_markdown_resource:151 - Bỏ qua 120806 vì nội dung Markdown không đổi trên Drive.

```

Hình 0.8: Chuyển đổi nội dung HTML đã làm sạch sang Markdown

Giai đoạn Tích hợp RAG pipeline:

- **step_rag_summary**: Sử dụng LLM viết một bản tóm tắt ngắn gọn mô tả bức tranh toàn cảnh của văn bản pháp luật đó.

```

step_rag_summary 20m 58s

1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_rag_summary.py
13 2026-06-16 00:40:38.359 | INFO | env:<module>:7 - Loading environment variables...
14 2026-06-16 00:40:51.101 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:113 - Bắt đầu lấy và khóa task cho step_code='step_rag_summary', limit=40
15 2026-06-16 00:40:51.803 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:148 - Đã khóa thành công 40 item(s) cho step_code='step_rag_summary'.
16 2026-06-16 00:40:53.801 | INFO | __main__:document_summary_resource:113 - Đang tải và tóm tắt tài liệu: 152024
17 2026-06-16 00:40:53.801 | DEBUG | utils.google_drive:download_from_drive:105 - Đang tải file từ URL: https://drive.google.com/file/d/1x1zgc30373HtM1u8uKpV26WnC3v1b0g/view
18 2026-06-16 00:40:54.990 | INFO | rag.llm:invoke_llm_chain:76 - Đang gọi Ollama...
19 2026-06-16 00:42:45.330 | INFO | utils.google_drive:get_or_create_drive_folder:52 - Folder 'step_rag_summary' đã tồn tại | ID: 1VddpV8wCtny501dyBh12NFTh15Axs
20 2026-06-16 00:42:45.333 | INFO | utils.google_drive:upload_to_drive:77 - Đang upload: 152024.txt (MimeType: text/plain)
21 2026-06-16 00:42:47.233 | SUCCESS | utils.google_drive:upload_to_drive:88 - File uploaded: 152024.txt | ID: 1FUIbFTpUqQeadyY3Y25a0GtG7uujtT
22 2026-06-16 00:42:47.233 | SUCCESS | utils.google_drive:upload_to_drive:89 - Link: https://drive.google.com/file/d/1FUIbFTpUqQeadyY3Y25a0GtG7uujtT/view
23 2026-06-16 00:42:47.233 | SUCCESS | __main__:document_summary_resource:141 - Đã cập nhật tóm tắt mới cho 152024
24 2026-06-16 00:42:47.386 | INFO | __main__:document_summary_resource:113 - Đang tải và tóm tắt tài liệu: 167147

```

Hình 0.9: Tự động tóm tắt văn bản bằng mô hình LLM

- **step_rag_chunking**: Chạy Semantic Chunking. LLM sẽ dựa vào bản tóm tắt và nội dung chi tiết để quyết định các "điểm cắt" tối ưu, chia nhỏ văn bản thành các đoạn (chunks) sao cho không bị đứt gãy ý nghĩa.

```

step_rag_chunking
1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_rag_chunking.py
13 2026-06-16 01:01:34.856 | INFO | env:(module):7 - Loading environment variables...
14 2026-06-16 01:01:42.939 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:113 - Bắt đầu lấy và khóa task cho step_code='step_rag_chunking', limit=40
15 2026-06-16 01:01:43.435 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:148 - Đã khóa thành công 35 item(s) cho step_code='step_rag_chunking'.
16 2026-06-16 01:01:44.884 | INFO | __main__:document_chunking_resource:192 - Đang tải dữ liệu Markdown & Summary cho tài liệu: 152024
17 2026-06-16 01:01:44.884 | DEBUG | utils.google_drive:download_from_drive:185 - Đang tải file từ URL: https://drive.google.com/file/d/1x1zgwC303J3HPIuWuKPy36HnC3vLb9q/view
18 2026-06-16 01:01:45.821 | DEBUG | utils.google_drive:download_from_drive:185 - Đang tải file từ URL: https://drive.google.com/file/d/1F1U1bftPuQoQvadyY3Y2Sa0Gt67uujtT/view
19 2026-06-16 01:01:46.887 | INFO | __main__:process_and_chunk:180 - Đang gọi LLM để đánh giá semantic chunking...
20 2026-06-16 01:01:46.369 | INFO | rag.llm:invoke_llm_chain:76 - Đang gọi Ollama...
21 2026-06-16 01:01:56.982 | INFO | __main__:process_and_chunk:187 - LLM Response: split_after: 3, 5, 8
22 2026-06-16 01:01:56.983 | INFO | __main__:document_chunking_resource:218 - Đã tạo 4 file chunks trong thư mục: /home/runner/work/data-pipeline-vbpInew/data-pipeline-vbpInew/data/step_rag_chunking/chunk_152024
23 2026-06-16 01:01:56.984 | INFO | __main__:document_chunking_resource:226 - Đang tải file nén lên Google Drive...
24 2026-06-16 01:01:57.660 | INFO | utils.google_drive:get_or_create_drive_folder:52 - Folder 'step_rag_chunking' đã tồn tại | ID: 1wvSP1yB0e2f6jleQfc1DvW-cGlg1-8
25 2026-06-16 01:01:57.662 | INFO | utils.google_drive:upload_to_drive:77 - Đang upload: chunk_zip_152024.zip (MimeType: application/zip)
26 2026-06-16 01:01:59.426 | SUCCESS | utils.google_drive:upload_to_drive:88 - File uploaded: chunk_zip_152024.zip | ID: 1Jv267MfHbnc1PgH2DTRKFrW5BUpS2T3
27 2026-06-16 01:01:59.427 | DEBUG | utils.google_drive:upload_to_drive:89 - Link: https://drive.google.com/file/d/1Jv267MfHbnc1PgH2DTRKFrW5BUpS2T3/view
28 2026-06-16 01:01:59.427 | SUCCESS | __main__:document_chunking_resource:239 - Đã xử lý phần mảnh (chunking) thành công cho 152024 (Drive ID: 1Jv267MfHbnc1PgH2DTRKFrW5BUpS2T3)
29 2026-06-16 01:01:59.567 | INFO | __main__:document_chunking_resource:192 - Đang tải dữ liệu Markdown & Summary cho tài liệu: 167147

```

Hình 0.10: Chia nhỏ văn bản dựa trên ý nghĩa (Semantic Chunking)

- **step_rag_context**: Đây là bước chống mất ngữ cảnh. LLM sẽ sinh ra ngữ cảnh cho từng đoạn chunk nhỏ vừa được cắt, đảm bảo mỗi chunk đều có thể đứng độc lập khi được tìm kiếm.

```

step_rag_context
1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_rag_context.py
13 2026-06-16 01:10:14.851 | INFO | env:(module):7 - Loading environment variables...
14 2026-06-16 01:10:23.079 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:113 - Bắt đầu lấy và khóa task cho step_code='step_rag_context', limit=40
15 2026-06-16 01:10:23.573 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:148 - Đã khóa thành công 30 item(s) cho step_code='step_rag_context'.
16 2026-06-16 01:10:25.545 | INFO | __main__:document_context_resource:141 - Đang tải dữ liệu tóm tắt và chunks cho: 152024
17 2026-06-16 01:10:25.545 | DEBUG | utils.google_drive:download_from_drive:185 - Đang tải file từ URL: https://drive.google.com/file/d/1F1U1bftPuQoQvadyY3Y2Sa0Gt67uujtT/view
18 2026-06-16 01:10:25.820 | DEBUG | utils.google_drive:download_from_drive:185 - Đang tải file từ URL: https://drive.google.com/file/d/1Jv267MfHbnc1PgH2DTRKFrW5BUpS2T3/view
19 2026-06-16 01:10:26.154 | INFO | __main__:document_context_resource:164 - Bắt đầu tạo ngữ cảnh cho 4 đoạn (chunks)...
20 2026-06-16 01:10:26.154 | INFO | __main__:document_context_resource:181 - Đang sinh ngữ cảnh cho chunk_2.md...
21 2026-06-16 01:10:26.462 | INFO | rag.llm:invoke_llm_chain:76 - Đang gọi Ollama...
22 2026-06-16 01:10:35.235 | INFO | __main__:document_context_resource:181 - Đang sinh ngữ cảnh cho chunk_1.md...
23 2026-06-16 01:10:35.910 | INFO | rag.llm:invoke_llm_chain:76 - Đang gọi Ollama...
24 2026-06-16 01:10:40.466 | INFO | __main__:document_context_resource:181 - Đang sinh ngữ cảnh cho chunk_3.md...
25 2026-06-16 01:10:40.771 | INFO | rag.llm:invoke_llm_chain:76 - Đang gọi Ollama...
26 2026-06-16 01:10:45.681 | INFO | __main__:document_context_resource:181 - Đang sinh ngữ cảnh cho chunk_4.md...
27 2026-06-16 01:10:46.409 | INFO | rag.llm:invoke_llm_chain:76 - Đang gọi Ollama...
28 2026-06-16 01:10:55.977 | INFO | __main__:document_context_resource:206 - Đang tải file Context Zip lên Google Drive...
29 2026-06-16 01:10:56.494 | INFO | utils.google_drive:get_or_create_drive_folder:52 - Folder 'step_rag_context' đã tồn tại | ID: 1vofe41ApNe_u_y5QhEWI2iaUrnN0c73t
30 2026-06-16 01:10:56.497 | INFO | utils.google_drive:upload_to_drive:77 - Đang upload: contextualized_152024.zip (MimeType: application/zip)
31 2026-06-16 01:10:58.250 | SUCCESS | utils.google_drive:upload_to_drive:88 - File uploaded: contextualized_152024.zip | ID: 18U8W0Dg74ybuOpux9qGYGF0Y2-TP1p
32 2026-06-16 01:10:58.250 | DEBUG | utils.google_drive:upload_to_drive:89 - Link: https://drive.google.com/file/d/18U8W0Dg74ybuOpux9qGYGF0Y2-TP1p/view
33 2026-06-16 01:10:58.250 | SUCCESS | __main__:document_context_resource:219 - Đã xử lý ngữ cảnh thành công cho 152024
34 2026-06-16 01:10:58.557 | INFO | __main__:document_context_resource:141 - Đang tải dữ liệu tóm tắt và chunks cho: 167147
35 2026-06-16 01:10:58.557 | DEBUG | utils.google_drive:download_from_drive:185 - Đang tải file từ URL: https://drive.google.com/file/d/1xx3jaij3g6Q0xC8mrvEKpITHTG@He8i/view
36 2026-06-16 01:10:58.889 | DEBUG | utils.google_drive:download_from_drive:185 - Đang tải file từ URL: https://drive.google.com/file/d/1BKFgktQxKTY9w407_BT6bn1e0RbELAQ/view
37 2026-06-16 01:10:59.191 | INFO | __main__:document_context_resource:164 - Bắt đầu tạo ngữ cảnh cho 1 đoạn (chunks)...
38 2026-06-16 01:10:59.191 | INFO | __main__:document_context_resource:181 - Đang sinh ngữ cảnh cho chunk_1.md...

```

Hình 0.11: Làm giàu ngữ cảnh cho từng đoạn văn bản nhỏ

- **step_rag_embedding**: Sử dụng mô hình HuggingFace (keepitreal/vietnamese-sbert) để biến đổi các đoạn văn bản (đã có ngữ cảnh) thành vector đa chiều và lưu trữ vào VectorDB (Pinecone).

```


step_rag_embedding
1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_rag_embedding.py
13 2026-06-16 01:20:37.004 | INFO | env:(module):7 - Loading environment variables...
14 Loading weights: 0% | 0/199 [00:00<?, ?it/s]
15 Loading weights: 100% | 199/199 [00:00:00:00, 22892.041t/s]
16 2026-06-16 01:20:59.683 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:113 - Bắt đầu lấy và khóa task cho step_code='step_rag_embedding', limit=150
17 2026-06-16 01:21:00.345 | INFO | utils.workflow_helper:fetch_and_lock_pending_tasks:148 - Đã khóa thành công 26 item(s) cho step_code='step_rag_embedding'.
18 2026-06-16 01:21:00.345 | INFO | __main__:document_embedding_resource:54 - Đang fetch toàn bộ metadata và history hàng loạt cho 26 items...
19 2026-06-16 01:21:07.816 | INFO | __main__:document_embedding_resource:176 - Đang tải và giải nén Chunks (Context) cho tài liệu: 152024
20 2026-06-16 01:21:07.817 | DEBUG | utils.google_drive:download_from_drive:185 - Đang tải file từ URL: https://drive.google.com/file/d/18U8W0Dg74ybuOpux9qGYGF0Y2-TP1p/view
21 2026-06-16 01:21:08.099 | INFO | __main__:document_embedding_resource:191 - Đang tạo vector và lưu vào database cho 4 chunks...
22 2026-06-16 01:21:10.188 | SUCCESS | __main__:document_embedding_resource:256 - Đã lưu 4 vectors vào Vector DB cho: 152024
23 2026-06-16 01:21:10.344 | INFO | __main__:document_embedding_resource:176 - Đang tải và giải nén Chunks (Context) cho tài liệu: 167155
24 2026-06-16 01:21:10.344 | DEBUG | utils.google_drive:download_from_drive:185 - Đang tải file từ URL: https://drive.google.com/file/d/1sB60x0Bq1wzgjZ1XYr-fu7K3qkRdP8TP/view
25 2026-06-16 01:21:10.602 | INFO | __main__:document_embedding_resource:191 - Đang tạo vector và lưu vào database cho 1 chunks...

```

Hình 0.12: Nhúng văn bản (Embedding) và lưu vào CSDL Pinecone

Các bước thực hiện mới:

- Nhờ vào việc nguồn dữ liệu thay đổi sang hệ thống API mới trả về cấu trúc JSON giàu thông tin, hệ thống không còn cần các bước bóc tách thủ công từ mã nguồn HTML phức tạp, giúp tăng tốc độ xử lý và độ chính xác của dữ liệu.
- Hệ thống loại bỏ bước `step_extract_document_info` vì nội dung Metadata chi tiết đã có trong API.
- Hệ thống loại bỏ bước `step_extract_document_content` vì nội dung văn bản đã được API trả trong thông tin `documentContent`.



Hình 0.13: Sơ đồ các bước thực hiện của quy trình mới


Kết quả vận hành thành công đường ống dữ liệu Văn bản pháp luật mới:

2026-06-16 01:01:15.216	SUCCESS	utils.workflow_helper:get_document_state_count_by_workflow:174 - Đã lấy thành công thống kê cho workflow
2026-06-16 01:01:15.222	DEBUG	utils.workflow_helper:get_document_state_count_by_workflow:201 - ID: 6, Count: 63
2026-06-16 01:01:15.222	DEBUG	utils.workflow_helper:get_document_state_count_by_workflow:201 - ID: 10, Count: 74798
2026-06-16 01:01:15.222	DEBUG	utils.workflow_helper:get_document_state_count_by_workflow:201 - ID: 14, Count: 92572
2026-06-16 01:01:18.594	SUCCESS	utils.workflow_helper:check_status_with_document_count:301 - Đã lấy thành công thống kê document theo status.
2026-06-16 01:01:18.594	INFO	utils.workflow_helper:check_status_with_document_count:305 - Còn hiệu lực(CHL): 72096
2026-06-16 01:01:18.594	INFO	utils.workflow_helper:check_status_with_document_count:305 - Không còn phù hợp(KCPH): 255
2026-06-16 01:01:18.594	INFO	utils.workflow_helper:check_status_with_document_count:305 - Chưa xác định(5): 0
2026-06-16 01:01:18.594	INFO	utils.workflow_helper:check_status_with_document_count:305 - Hết hiệu lực một phần(HHL1P): 5290
2026-06-16 01:01:18.594	INFO	utils.workflow_helper:check_status_with_document_count:305 - Ngưng hiệu lực một phần(TNHL1P): 2
2026-06-16 01:01:18.594	INFO	utils.workflow_helper:check_status_with_document_count:305 - Ngưng hiệu lực(TNHL): 369
2026-06-16 01:01:18.594	INFO	utils.workflow_helper:check_status_with_document_count:305 - Chưa có hiệu lực(CCHL): 149
2026-06-16 01:01:18.594	INFO	utils.workflow_helper:check_status_with_document_count:305 - Hết hiệu lực toàn bộ(HHL): 86641


Hình 0.14: Kết quả chạy các bước luồng dữ liệu VBPL mới (Phần 1)

Từ kết quả chạy các bước luồng dữ liệu VBPL mới, trong database postgres hiện đang có kết quả số lượng tài liệu chi tiết theo từng trạng thái hiệu lực:

- Còn hiệu lực (CHL): 72.096
- Không còn phù hợp (KCPH): 255
- Chưa xác định (5): 0
- Hết hiệu lực một phần (HHL1P): 5.290
- Ngưng hiệu lực một phần (TNHL1P): 2
- Ngưng hiệu lực (TNHL): 369
- Chưa có hiệu lực (CCHL): 149
- Hết hiệu lực toàn bộ (HHL): 86.641




Hình 0.15: Kết quả chạy các bước luồng dữ liệu VBPL mới (Phần 2)



Hình 0.16: Kết quả chạy các bước luồng dữ liệu VBPL mới (Phần 3)


0.0.2 Đường ống dữ liệu Pháp Điện

Sơ đồ tổng quan Data pipeline Pháp Điện




Hình 0.17: Sơ đồ thu thập dữ liệu chung

Tổng quan thông tin file zip




Hình 0.18: Sơ đồ thu thập dữ liệu chung

Kết quả file JSON đã trích xuất




Hình 0.19: Sơ đồ thu thập dữ liệu chung

Kết quả vector được lưu trong vector database




Hình 0.20: Sơ đồ thu thập dữ liệu chung




Hình 0.21: Sơ đồ thu thập dữ liệu chung

Quá trình Data pipeline được chia thành 3 giai đoạn: Thu thập dữ liệu, Tiền xử lý văn bản và Tích hợp RAG Pipeline.

- **step_download_zip:** Tự động tải file nén chứa toàn bộ Bộ Pháp Điển điện tử từ nguồn Cổng thông tin điện tử Pháp Điển. Hệ thống tính toán mã băm (MD5) và đồng bộ với Google Drive để kiểm tra sự thay đổi dữ liệu.




Hình 0.22: Tự động tải file nén mới và đồng bộ Google Drive




Hình 0.23: Kiểm tra mã băm và bỏ qua bước tải nếu không có sự thay đổi dữ liệu

- **step_extract_json** và **step_load_json**: Từ file `jsonData.js`, tiến hành bóc tách (parse) các biến cấu trúc dữ liệu để lấy danh sách Chủ đề (`jdChuDe`), Đề mục (`jdDeMuc`) và Cây mục lục (`jdAllTree`), sau đó xuất ra định dạng JSON.




Hình 0.24: Bóc tách biến cấu trúc dữ liệu và xuất ra file JSON



Hình 0.25: Nạp dữ liệu JSON vào hệ thống

- **step_rag_chunking**: Thực hiện đối chiếu từ Cây mục lục (`jdAllTree`) với các thẻ bên trong từng file HTML chi tiết. Từ đó, bóc tách chính xác từng phần nội dung văn bản thành dạng JSON có các đoạn văn bản và siêu dữ liệu (Metadata).



Hình 0.26: Bóc tách và chia nhỏ nội dung văn bản theo cấu trúc mục lục

- **step_rag_embedding**: Làm giàu ngữ cảnh bằng cách nối trực tiếp tên Chủ đề và Đề mục vào phần đầu của mỗi đoạn văn bản chunk. Sau đó, nội dung được đưa qua mô hình HuggingFace (keepitreal/vietnamese-sbert) để biến đổi thành các vector và lưu vào CSDL vector Qdrant.

```

step_rag_embedding 1m 34s

1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_rag_embedding.py
13 2026-06-16 01:02:18.641 | INFO | env:<module>:7 - Loading environment variables...
15 Loading weights: 0%| 0/199 [00:00<?, ?it/s]
16 Loading weights: 100%| 199/199 [00:00<00:00, 20000.18it/s]
17 RobertaModel LOAD REPORT from: keepitreal/vietnamese-sbert
18 Key | Status | |
19 -----+-----+
20 embeddings.position_ids | UNEXPECTED | |
21 Notes:
22 - UNEXPECTED: can be ignored when loading from different task/architecture; not ok if you expect identical arch.
24 2026-06-16 01:02:39.076 | INFO | rag.vectorstore:<module>:30 - Qdrant collection 'prod_phap_dien_vectors' đã sẵn sàng.
25 2026-06-16 01:02:40.183 | INFO | utils.google_drive:get_or_create_drive_folder:58 - Folder 'step_rag_embedding' đã tồn tại | ID: 17nJm8kl109pZs_lyx29v-_E6uphNKR
26 2026-06-16 01:02:40.617 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File '995b0a50-c2a1-45d8-baf6-a0b02c7821cf.json' không thay đổi (MD5 khớp). Bỏ qua upload.
27 2026-06-16 01:02:41.134 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File '2162aa7c-d532-413b-8704-b82973267484.json' không thay đổi (MD5 khớp). Bỏ qua upload.
28 2026-06-16 01:02:41.486 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'ad9817c1-1032-4748-97f7-fd4db42fd04e.json' không thay đổi (MD5 khớp). Bỏ qua upload.
29 2026-06-16 01:02:41.833 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'd0a39796-1eb4-4862-972b-87d5ad87ae2c.json' không thay đổi (MD5 khớp). Bỏ qua upload.
30 2026-06-16 01:02:42.206 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'c78e4b28-0d12-4211-98a5-47fbbd144f7b.json' không thay đổi (MD5 khớp). Bỏ qua upload.
31 2026-06-16 01:02:42.526 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'f549c597-2521-4480-bc28-505b06f2e22f.json' không thay đổi (MD5 khớp). Bỏ qua upload.
32 2026-06-16 01:02:42.918 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File '34030833-66c0-4966-9dff-1f02e805d94f.json' không thay đổi (MD5 khớp). Bỏ qua upload.
33 2026-06-16 01:02:43.269 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File '3284cd8d-f598-48ea-b425-53e118893530.json' không thay đổi (MD5 khớp). Bỏ qua upload.

```

Hình 0.27: Mô hình hóa dữ liệu dạng vector và lưu trữ vào Qdrant

```

data_pipeline
succeeded 5 days ago in 52s

> Set up Python 0s
> Install dependencies 19s
v step_download_zip 25s

1 ▶ Run doppler run -p 20206205tech -c prod -- uv run python step_download_zip.py
13 2026-06-16 05:00:53.684 | INFO | env:<module>:7 - Loading environment variables...
14 2026-06-16 05:00:54.134 | INFO | __main__:download_file:26 - Đang tải file từ: https://phapdien.moj.gov.vn/TraCuuPhapDien/Files/BoPhapDienDienTu.zip
15 2026-06-16 05:01:15.492 | SUCCESS | __main__:download_file:34 - Tải xong: /home/runner/work/data-pipeline-phapdien/data-pipeline-phapdien/data/step_download_zip/phapdien_latest.zip
16 2026-06-16 05:01:16.017 | INFO | utils.google_drive:get_or_create_drive_folder:58 - Folder 'step_download_zip' đã tồn tại | ID: 1rNG1IVrHBjWxMbsqQ08Z1xRi3b5hok
17 2026-06-16 05:01:16.267 | INFO | utils.google_drive:sync_local_file_to_drive:241 - File 'phapdien_latest.zip' không thay đổi (MD5 khớp). Bỏ qua upload.
18 2026-06-16 05:01:16.267 | SUCCESS | __main__:main:88 - File ZIP không đổi. Bỏ qua bước giải nén và các step tiếp theo trên GitHub Actions.

○ step_extract_json 0s
○ step_load_json 0s
○ step_rag_chunking 0s
○ step_rag_embedding 0s

```

Hình 0.28: Sơ đồ thu thập dữ liệu chung